**ANALISIS DATA STATISTIK – SS234523**

# PERAMALAN INDEKS HARGA YANG DITERIMA PETANI (IT) DI PROVINSI NTB DAN NTT MENGGUNAKAN METODE VECTOR AUTOREGRESSIVE (VAR)


**Rizal Afandi**

NRP 5003221116

**Ida Bagus Panya Ananda Yogi**

NRP 5003221154

Dosen Pembimbing

**Dr. Irhamah, S.Si., M.Si.**

NIP 19780406 200112 2 002

**Program Studi Statistika**

Departemen Statistika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya


2025

# ABSTRAK

**PERAMALAN INDEKS HARGA YANG DITERIMA PETANI (IT) DI PROVINSI NTB DAN NTT MENGGUNAKAN METODE VECTOR AUTOREGRESSIVE (VAR)**


| | | |
|---|---|---|
| **Nama Mahasiswa / NRP** | **:** | **Rizal Afandi / 5003221116** |
| | | **Ida Bagus Panya Ananda Yogi / 5003221116** |
| **Departemen** | **:** | **Statistika FSAD - ITS** |
| **Dosen Pembimbing** | **:** | **Dr. Irhamah, S.Si., M.Si.** |



**Abstrak**

Pertanian merupakan sektor strategis dalam perekonomian daerah, khususnya di Provinsi Nusa Tenggara Barat (NTB) dan Nusa Tenggara Timur (NTT), yang sebagian besar penduduknya bergantung pada hasil pertanian. Salah satu indikator penting untuk mengukur kesejahteraan petani adalah Indeks Harga yang Diterima Petani (IT). Fluktuasi IT yang dipengaruhi berbagai faktor eksternal memerlukan metode peramalan yang akurat guna mendukung pengambilan kebijakan yang tepat sasaran. Penelitian ini bertujuan untuk meramalkan IT di NTB dan NTT menggunakan metode Vector Autoregressive (VAR). Data IT bulanan periode Januari 2019 hingga Mei 2025 dianalisis melalui tahap pemeriksaan stasioneritas, pemilihan model optimal dengan kriteria AIC, estimasi parameter, serta pengujian asumsi residual. Model terbaik yang diperoleh adalah VAR(1) setelah satu kali differencing. Hasil uji kausalitas menunjukkan adanya pengaruh signifikan dari IT_NTT terhadap IT_NTB, namun tidak sebaliknya. Uji diagnostik membuktikan bahwa model memenuhi asumsi white noise, normalitas, dan homoskedastisitas. Evaluasi akurasi peramalan menunjukkan nilai Mean Absolute Percentage Error (MAPE) di bawah 4%, mengindikasikan tingkat akurasi yang sangat baik secara numerik. Meskipun demikian, hasil visual menunjukkan model kurang mampu mengikuti dinamika tren aktual yang terus meningkat. Penelitian ini merekomendasikan penambahan variabel eksternal dan eksplorasi model alternatif guna meningkatkan kemampuan prediksi jangka panjang.



**Kata kunci:** ***Indeks Harga yang Diterima Petani, VAR, Peramalan, NTB, NTT, Time Series.***

# DAFTAR ISI

ABSTRAK ..... i
DAFTAR ISI ..... ii
DAFTAR GAMBAR ..... iv
DAFTAR TABEL ..... v
BAB 1 PENDAHULUAN ..... 6
1.1 Latar Belakang ..... 6
1.2 Rumusan Masalah ..... 6
1.3 Batasan Masalah ..... 6
1.4 Tujuan ..... 7
1.5 Manfaat ..... 7
BAB 2 TINJAUAN PUSTAKA ..... 8
2.1 Analisis Deret Waktu (*Time Series*) ..... 8
2.2 Stasioneritas ..... 8
2.3 *Granger Causality* ..... 9
2.4 *Autocorrelation Function* (ACF) ..... 9
2.5 *Partial Autocorrelation Function* (PACF) ..... 10
2.6 Analisis Deret Waktu Multivariat (*Time Series Multivariate*) ..... 10
*2.7* Stasioneritas Model Multivariate Time Series ..... 10
*2.8 Vector Autoregressive (VAR)* ..... 11
2.9 *Matrix Autocorrelation Function* (MACF) ..... 11
2.10 *Matrix Partial Autocorrelation Function* (MPACF) ..... 12
2.11 Uji Diagnosis Model ..... 12
2.12 Uji *Portmanteau* ..... 12
2.13 Pengecekan Asumsi Distribusi Normal ..... 13
2.14 Asumsi Homoskedastisitas Residual ..... 13
2.15 Pemilihan Model Terbaik ..... 13
BAB 3 METODOLOGI ..... 15
3.1 Sumber Data ..... 15
3.2 Variabel Penelitian ..... 15
3.3 Metode Analisis Data ..... 15
BAB 4 HASIL DAN PEMBAHASAN ..... 17
4.1 Karakteristik Data ..... 17

4.2 Identifikasi Hubungan Kausalitas ..... 18
4.3 Identifikasi Stationer pada Data Time Series ..... 18
4.3.1 Stationer dalam Varians ..... 18
4.3.2 Stationer dalam Mean ..... 19
4.4 Pemilihan Model VAR Sementara ..... 20
4.5 Estimasi Parameter Model VAR ..... 20
4.6 Pemeriksaan Asumsi Residual ..... 21
4.6.1 Uji White Noise ..... 21
4.6.2 Uji Normalitas ..... 22
4.6.3 Uji Heteroskedastisitas ..... 22
4.7 Model Terbaik ..... 22
4.8 Peramalan dan Evaluasi Akurasi Prediksi ..... 23
BAB 5 KESIMPULAN DAN SARAN ..... 25
5.1 Kesimpulan ..... 25
5.2 Saran ..... 25
DAFTAR PUSTAKA ..... 27
LAMPIRAN ..... 28

# DAFTAR GAMBAR

**Gambar 3.1** Diagram Alir Membentuk Model VAR ..... 16
**Gambar 4.1** Time Series Plot (a) NTB, (b) NTT ..... 17
**Gambar 4.2** MACF Sebelum Differencing ..... 19
**Gambar 4.3** Plot Time Series Hasil Peramalan model VAR(1) (a) IT_NTB, (b) IT_NTT .... 24

# DAFTAR TABEL

**Tabel 2.1** Transformasi Box-Cox ..... 9
**Tabel 2.2** Pola ACF dan PACF dari Deret Waktu Stasioner ..... 10
**Tabel 3.1** Struktur Data ..... 15
**Tabel 4.1** Statistik Deskriptif IT di Dua Provinsi ..... 17
**Tabel 4.2** Hasil Uji Kausalitas antar Variabel ..... 18
**Tabel 4.3** Identifikasi Stationer dalam Varians Setelah Transformasi ..... 19
**Tabel 4.4** Hasil Stationer dalam Mean setelah Differencing 1 ..... 19
**Tabel 4.5** AIC Model VAR ..... 20
**Tabel 4.6** Estimasi Parameter model VAR(1) ..... 20
**Tabel 4.7** Estimasi Parameter model VAR(1) setelah restrict ..... 21
**Tabel 4.8** Pengujian White Noise variabel IT_NTB ..... 21
**Tabel 4.9** Pengujian White Noise variabel IT_NTT ..... 21
**Tabel 4.10** Pengujian Normalitas menggunakan Jarque-Bera ..... 22
**Tabel 4.11** Pengujian Heteroskedastisitas menggunakan ARCH-LM ..... 22
**Tabel 4.12** Peramalan Indeks Tani NTB dn NTT ..... 23
**Tabel 4.13** Evaluasi MAPE model terbaik VAR(1) ..... 24

# BAB 1
# PENDAHULUAN

## 1.1 Latar Belakang

Pertanian merupakan sektor strategis yang memegang peranan penting dalam struktur perekonomian nasional, khususnya di daerah yang memiliki ketergantungan tinggi terhadap aktivitas agraris seperti Provinsi Nusa Tenggara Barat (NTB) dan Nusa Tenggara Timur (NTT). Kegiatan ekonomi masyarakat di kedua wilayah ini sebagian besar bergantung pada hasil pertanian sebagai sumber utama pendapatan dan penunjang kesejahteraan rumah tangga. Oleh sebab itu, fluktuasi dalam sektor pertanian memiliki implikasi langsung terhadap kondisi sosial ekonomi masyarakat.

Salah satu indikator yang digunakan untuk mengukur tingkat kesejahteraan petani adalah Indeks Harga yang Diterima Petani (IT). Indeks ini mencerminkan perubahan rata-rata harga yang diterima petani atas produk yang mereka hasilkan pada periode tertentu. Stabilitas IT penting untuk menjaga daya beli petani, mendorong keberlanjutan usaha tani, dan sebagai dasar dalam perumusan kebijakan pembangunan pertanian. Namun demikian, IT cenderung bersifat fluktuatif, dipengaruhi oleh berbagai faktor internal maupun eksternal, seperti kondisi iklim, biaya produksi, perubahan permintaan, kebijakan perdagangan, serta dinamika harga komoditas global.

Dalam upaya mitigasi risiko dan perencanaan kebijakan yang lebih tepat sasaran, diperlukan suatu model peramalan yang mampu memproyeksikan perkembangan IT secara akurat. Salah satu pendekatan yang relevan dalam analisis data deret waktu multivariat adalah *Vector Autoregressive* (VAR). Model VAR memungkinkan pengujian hubungan dinamis antar beberapa variabel ekonomi secara simultan, tanpa mengharuskan adanya asumsi a priori tentang variabel independen maupun dependen, sehingga mampu menangkap keterkaitan kompleks antar faktor-faktor yang mempengaruhi IT.

Penelitian ini bertujuan untuk meramalkan Indeks Harga yang Diterima Petani di Provinsi NTB dan NTT dengan menggunakan metode VAR. Dengan adanya hasil peramalan yang komprehensif, diharapkan penelitian ini dapat memberikan kontribusi empiris bagi penguatan kebijakan pembangunan pertanian, pengambilan keputusan investasi usaha tani, serta peningkatan ketahanan ekonomi daerah dalam menghadapi dinamika perekonomian yang semakin kompleks.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang yang dijelaskan sebelumnya, maka permasalahan yang dibahas adalah:

1. Bagaimana model *Vector Autoregressive* (VAR) yang terbentuk untuk kasus Indeks Harga yang Diterima Petani (IT) di Provinsi NTB dan NTT?
2. Seberapa baik kinerja model *Vector Autoregressive (VAR)* dalam meramalkan Indeks Harga yang Diterima Petani (IT) di Provinsi NTB dan NTT?
3. Bagaimana keterkaitan antar provinsi dalam membentuk Indeks Harga yang Diterima Petani (IT)?

## 1.3 Batasan Masalah

Batasan penelitian ini adalah pada penggunaan data bulanan Indeks Harga yang Diterima Petani (IT) di Provinsi NTB dan NTT periode Januari 2019 – Mei 2025 Dan analisis yang

digunakan dalam studi kasus ini adalah model *Multivariate Time Series* dengan metode *Vector Autoregression* (VAR).

## 1.4 Tujuan

Berdasarkan rumusan masalah, tujuan yang ingin dicapai peneliti dalam penelitian adalah sebagai berikut:

1. Mendapatkan model *Vector Autoregressive* (VAR) untuk kasus Indeks Harga yang Diterima Petani (IT) di Provinsi NTB dan NTT?
2. Mendapatkan metrik Seberapa baik kinerja model *Vector Autoregressive (VAR)* dalam meramalkan Indeks Harga yang Diterima Petani (IT) di Provinsi NTB dan NTT?
3. Menjelaskan keterkaitan antar provinsi dalam membentuk Indeks Harga yang Diterima Petani (IT)?

## 1.5 Manfaat

Penelitian ini diharapkan dapat memberikan kontribusi ilmiah dalam pengembangan model peramalan deret waktu multivariat di bidang ekonomi pertanian dengan menggunakan metode VAR, sekaligus menyediakan hasil peramalan Indeks Harga yang Diterima Petani (IT) yang bermanfaat sebagai masukan praktis bagi pemerintah daerah, pelaku usaha, dan perumus kebijakan dalam menyusun strategi pengembangan dan stabilisasi sektor pertanian di Provinsi NTB dan NTT.

# BAB 2
# TINJAUAN PUSTAKA

## 2.1 Analisis Deret Waktu (*Time Series*)

Analisis time series merupakan salah satu prosedur statistika yang diterapkan untuk meramalkan struktur probabilitas keadaan yang akan terjadi di masa yang akan datang dalam rangka pengambilan keputusan (Wei, 2006). Secara umum, metode peramalan dibagi dalam dua kelompok utama, yaitu metode kualitatif (subjektif) dan metode kuantitatif. Metode peramalan kualitatif lebih mengandalkan judgement dan intuisi manusia daripada menggunakan data historis yang dimiliki. Sedangkan peramalan kuantitatif dapat diterapkan apabila tersedia informasi tentang masa lalu yang dapat dikuantitatifkan dalam bentuk data numerik, dimana diasumsikan beberapa aspek pola masa lalu akan terus berlanjut di masa mendatang (Wei, 2006).

Secara garis besar permodelan data pada analsisi time series terbagi atas dua klasifikasi yaitu univariate dan multivariate. Pada model univariate peramalan data suatu variabel hanya didasarkan pada nilai variabel tersebut pada masa lampau sedangkan pada model multivariate, peramalan data dilakukan dengan menambahkan variabel lain yang mempunyai hubungan jangka panjang untuk mendapatkan keakuratan peramalan. Pengelompokan model time series yang digunakan juga dibagi menjadi dua yaitu model time series linier dan nonlinier.

## 2.2 Stasioneritas

Time series dikatakan stasioner jika tidak ada kecenderungan perubahan dalam rata-rata dan perubahan variansi. Dengan kata lain, time series yang stasioner adalah relative tidak terjadi kenaikan maupun penurunan nilai secara tajam pada data atau fluktuasi data berada pada sekitar nilai rata-rata yang konstan (Wei, 2006).

Kondisi stasioner terdiri atas dua hal, yaitu stasioner dalam rata-rata *(mean)* dan stasioner dalam varian. Dikatakan stasioner apabila nilai $\mu, \gamma_k$ dan $\sigma^2$ tidak bergantung pada waktu pengamatan (Wei, 2006). Hal tersebut dapat ditulis sebagai berikut:

$$E(Z_t) = E(Z_{t+k}) = \mu$$

$$Var(Z_t) = E(Z_t - \mu)^2 = \sigma^2$$

$$Cov(Z_t, Z_{t+k}) = E[(Z_t - \mu)(Z_{t+k} - \mu)] = \gamma_k$$

Dalam pemodelan deret waktu univariat, kestasioneran data terhadap rata-rata dapat diamati secara visual melalui plot ACF dari data observasi. Sementara itu, kestasioneran terhadap varians dapat dilihat menggunakan plot Box-Cox. Apabila plot ACF menunjukkan penurunan yang lambat, hal ini menandakan bahwa data belum stasioner terhadap rata-rata. Oleh karena itu, proses *differencing* perlu diterapkan untuk mencapai kestasioneran data (Makridakis et al., 1999), dengan rumusan sebagai berikut:

$$Y_t = Z_t - Z_{t-1}$$

dimana $Y_t$ merupakan Data hasil *differencing*, $Z_t$ adalah Variabel Z pada waktu ke-*t* dan t adalah waktu kejadian.

Proses untuk menstasionerkan data dalam varians dapat dilakukan dengan menggunakan transformasi Box-Cox. Untuk suatu nilai parameter λ, transformasi didefinisikan dengan persamaan sebagai berikut:

$$T(Z_t) = \begin{cases} \dfrac{Z_t^{\lambda} - 1}{\lambda}, & \lambda \neq 0 \\ lim_{\lambda \to 0} \dfrac{Z_t^{\lambda} - 1}{\lambda} = \ln(Z_t), & \lambda = 0 \end{cases}$$

Berikut adalah transformasi yang dapat dilakukan untuk beberapa nilai $\lambda$

**Tabel 2.1** Transformasi Box-Cox

| Nilai $\boldsymbol{\lambda}$ | Transformasi |
|---|---|
| **-1,0** | $\frac{1}{Z_t}$ |
| **-0,5** | $\frac{1}{\sqrt{Z_t}}$ |
| **0** | $lnZ_t$ |
| **0,5** | $\sqrt{Z_t}$ |
| **1,0** | $Z_t$ (tidak transformasi) |

## 2.3 *Granger Causality*

Dalam analisis deret waktu multivariat, sering kali arah hubungan kausal antar variabel tidak dapat diidentifikasi secara langsung hanya dengan melihat data (Enders, 1995). Oleh sebab itu, dibutuhkan suatu metode khusus untuk menguji keberadaan hubungan kausalitas di antara variabel-variabel tersebut, salah satunya dengan menggunakan uji *Granger Causality.* Uji ini berfungsi untuk menilai apakah suatu variabel memiliki kontribusi informasi yang signifikan dalam memprediksi variabel lainnya. Hipotesis pengujian hubungan kausalitas dengan Granger Causality adalah sebagai berikut,

$H_0 : f_{21} = 0$ ($Z_{1t}$ bukan penyebab $Z_{2t}$),

$H_1 : f_{21} \neq 0$ ($Z_{1t}$ penyebab $Z_{2t}$).

Penolakan hipotesis dilakukan dengan menggunakan statistic uji chi-square berikut,

$$x^2 = (n - (pm^2 - m))(\log\left|\sum_r\right| - |\sum_u|)$$

dimana *n* merupakan banyak observasi yang digunakan, *p* adalah parameter, $\sum_r$ adalah matriks varians kovarian residual model *restricted* dan $\sum_u$ adalah matriks varians kovarian residual model *unrestricted*. $H_0$ ditolak jika $x^2 > x^2_{(\alpha;df)}$ atau $p - value < \alpha$.

## 2.4 *Autocorrelation Function* (ACF)

Suatu proses stasioner $\{Z_t\}$ mempunyai nilai mean $E\{Z_t\} = \mu$ dan $Var(Z_t) = E(Z_t - \mu_t)^2 = \sigma^2$ yang konstan serta kovarian $(Z_t, Z_s)$ yang fungsinya hanya berbeda dalam waktu $|t - s|$. Kovarian diantara $Z_t$ dan $Z_{t+k}$ adalah (Wei, 2006):

$$\gamma_k = Cov(Z_t, Z_{t+k}) = E(Z_t - \mu)(Z_{t+k} - \mu)$$

dan korelasi antara $Z_t$ dan $Z_{t+k}$ berdasarkan Wei (2006) adalah:

$$\rho_k = \frac{Cov(Z_t, Z_{t+k})}{\sqrt{var(Z_t)} + \sqrt{var(Z_{t+k})}} = \frac{\gamma_k}{\gamma_0}$$

dimana sebagai fungsi dari $k$, $\gamma_k$ merupakan fungsi autokovarians dan $\rho_k$ merupakan fungsi autokorelasi.

## 2.5 *Partial Autocorrelation Function* (PACF)

Fungsi autokorelasi parsial digunakan untuk mengukur tingkat keeratan antara $Z_t$ dan $Z_{t+k}$. Fungsi autokorelasi parsial dinotasikan dengan $\phi_{k+1,k+1}$ dan dirumuskan sebagai berikut:

$$\phi_{k+1,k+1} = \frac{\rho_{k+1} - \sum_{j=1}^{k} \phi_{kj}\rho_{k+1-j}}{1 - \sum_{j=1}^{k} \phi_{kj}\rho_j}$$

dengan $\phi_{kj} = \phi_{k-1,j} - \phi_{kk}\phi_{k-1,k-1}$ , $j = 1,2, \dots, k$

Pola pada plot ACF dan PACF dari deret waktu yang stasioner dapat digunakan untuk mengidentifikasi model *time series,* dengan penjelasan seperti yang dapat dilihat pada Tabel 2.2.

**Tabel 2.2** Pola ACF dan PACF dari Deret Waktu Stasioner

| Model | Pola ACF | Pola PACF |
|---|---|---|
| $\boldsymbol{AR_{(p)}}$ | *Dies down* (Turun cepat secara eksponensial) | *Cuts off* (Terputus setelah lag *p*) |
| $\boldsymbol{MA_{(q)}}$ | *Cuts off* (Terputus setelah lag *q*) | *Dies down* (Turun cepat secara eksponensial) |
| $\boldsymbol{ARMA_{(p,q)}}$ | *Dies down* (Turun cepat secara eksponensial) | *Dies down* (Turun cepat secara eksponensial) |

## 2.6 Analisis Deret Waktu Multivariat (*Time Series Multivariate*)

*Multivariate time series* merupakan deret waktu yang terdiri dari beberapa variabel. Identifikasi pada model *multivariate time series* hampir sama dengan model univariate time series. Identifikasi dilakukan berdasarkan pola atau matriks fungsi korelasi (MACF) dan matriks fungsi korelasi parsial (MACF) setelah data stasioner (Wei, 2006).

## *2.7* Stasioneritas Model Multivariate Time Series

Stasioneritas dalam model multivariat mengacu pada kestabilan distribusi probabilitas gabungan dari beberapa variabel sepanjang waktu. Stasioneritas ini penting karena banyak metode pemodelan deret waktu) mengasumsikan bahwa data bersifat stasioner agar estimasi parameter valid dan prediksi akurat. Kestasioneran data dalam *mean* secara visual dapat terlihat dalam plot MACF. Data dikatakan belum stasioner dalam mean apabila di Plot MACF turun secara lambat *(dies down)*. Untuk mengatasi ini perlu dilakukan proses *differencing* data.

Sedangkan kestasioneran data dalam varian dapat dilihat dari nilai *rounded value* ≠1. Untuk mengatasi ini dapat digunakan transformasi *Box-Cox.*

## *2.8 Vector Autoregressive (VAR)*

Enders (2004) menjelaskan bahwa model VAR adalah sistem persamaan dinamis di mana nilai sebuah variabel pada waktu tertentu dipengaruhi oleh nilai-nilai lampau dari variabel itu sendiri, serta nilai-nilai lampau dari variabel-variabel lain yang menjadi bagian dari sistem. Konseptualnya, model VAR serupa dengan model *Autoregressive* (AR) univariat. Namun, jika orde (p) pada model AR ditentukan melalui fungsi autokorelasi parsial (PACF), pada model VAR, orde optimal diidentifikasi menggunakan fungsi autokorelasi parsial matriks (MPACF).

Pemodelan VAR tidak jauh berbeda dengan model *Autoregressive* (AR), dimana model AR diidentifikasi dari *partial autocorrelation function* (PACF) dalam menentukan orde ke-p, sedangkan pada model VAR diidentifikasi dari *matrix partial autocorrelation function* (MPACF). Pada model VAR asumsi yang harus dipenuhi adalah sama dengan model AR, yaitu data harus stasioner dalam mean dan varian serta *error* harus *white noise*. Secara umum model VAR(p) dapat ditulis sebagai berikut:

$$Z_t = \tau + \Phi_1 Z_{t-1} + \ldots + \Phi_p Z_{t-p} + a_t$$

dengan:

$Z_t$ : vektor Z pada waktu ke-*t*

$\tau$ : vektor konstanta

$\Phi_1$ : matriks parameter ke-1

$\Phi_p$ : matriks parameter ke-p

$a_t$ : vektor residual pada waktu t

## 2.9 *Matrix Autocorrelation Function* (MACF)

Fungsi matrik korelasi sampel dari n pengamatan $Z_1, Z_2, \ldots, Z_n$ dapat dinyatakan sebagai berikut:

$$\hat{\rho}_{ij}(k) = \frac{\sum_{t=1}^{n-k}(Z_{i,t} - \bar{Z}_i)(Z_{j,t+k} - \bar{Z}_j)}{\left[\sum_{t=1}^{n}(Z_{i,t} - \bar{Z}_i)^2 \sum_{t=1}^{n}(Z_{j,t} - \bar{Z}_j)^2\right]}$$

Dimana $\bar{Z}_i$ dan $\bar{Z}_j$ merupakan mean sampel dari komponen dari deret yang bersesuaian.

Fungsi matriks korelasi sampel sangat diperlukan dalam model MA, jika matriks korelasinya bernilai nol setelah lag ke-q maka model yang bersesuaian adalah MA(q). Tiao dan Box dalam Wei (2006) mengenalkan sebuah metode yang sesuai dalam menerangkan korelasi sampel. Metode yang dikenalkan adalah 13 menggunakan simbol yang dinotasikan dengan (+), (-), dan (.) pada matriks korelasi sampel ke (i,j).

1. simbol (+) diartikan sebagai $\hat{p}_{ij}(k)$ lebih besar dari 2 kali standar error dan menunjukkan hubungan memiliki korelasi positif.
2. simbol (-) menyatakan suatu nilai $\hat{p}_{ij}(k)$ kurang dari -2 kali standar error dan menunjukkan hubungan memiliki korelasi negative.

3. simbol (.) menotasikan $\hat{p}_{ij}(k)$ berada diantara ±2 kali standar error dan menunjukkan tidak adanya korelasi.

## 2.10 *Matrix Partial Autocorrelation Function* (MPACF)

Tiao dan Box dalam Wei (2006) yang mendefinisikan matriks autokorelasi parsial pada lag k dengan notasi $\mathcal{P}(k)$. Persamaan untuk matriks autokorelasi parsial adalah sebagai berikut:

$$\mathcal{P}(k) = \begin{cases} \Gamma'(1)[\Gamma(0)]^{-1} & ,k = 1 \\ (\Gamma'(1) - c'(k)[A(k)]^{-1}b(k))\left(\Gamma(0) - b'(k)[A(k)]^{-1}b(k)\right)^{-1} & ,k > 1 \end{cases}$$

dengan nilai $A(k)$, $b(k)$, dan $c(k)$ adalah sebagai berikut:

$$A(k) = \begin{bmatrix} \Gamma(0) & \Gamma(1) & \cdots & \Gamma'(k-2) \\ \Gamma(1) & \Gamma(0) & \cdots & \Gamma'(k-3) \\ \vdots & \vdots & \ddots & \vdots \\ \Gamma(k-2) & \Gamma(k-3) & \cdots & \Gamma(0) \end{bmatrix}, b(k) = \begin{bmatrix} \Gamma'(k-1) \\ \Gamma'(k-2) \\ \vdots \\ \Gamma'(1) \end{bmatrix}, c(k) = \begin{bmatrix} \Gamma(1) \\ \Gamma(2) \\ \vdots \\ \Gamma(k-1) \end{bmatrix}$$

*Matrix Autocoreation Function* (MACF) dan *Matrix Partial Autocorrelation Function* (MPACF) dapat menjadi indikasi dari Stasioneritas dari *multivariate time series* secara visual. juga dapat dilihat dari eigen value parameter model VAR (Wei, 2006). Misalkan model VAR (1) sebagai berikut:

$$(1 - \phi_1 B)Z_t = a_t, \text{ dimana } \phi_1 = \begin{bmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{bmatrix}$$

jika nilai eigen dari $\phi_1 < 1$, yang berarti berada dalam lingkaran satuan maka dapat dikatakan bahwa proses stasioner (Wei, 2006).

## 2.11 Uji Diagnosis Model

Uji diagnosis dapat dibagi ke dalam dua bagian, yaitu uji signifikansi parameter dan uji kesesuaian model yang terdiri dari uji asumsi *multivariate white noise* dan distribusi normal *multivariate* dari residual.

## 2.12 Uji *Portmanteau*

Uji *Portmanteau* digunakan untuk memeriksa apakah residual *white noise* atau tidak. Hipotesis dari uji *Portmanteau* sebagai berikut:

$H_0$: $r_1 = \ldots = r_h = 0$ (Residual telah memenuhi asumsi *white noise*).

$H_1$: Minimal ada satu $r_i \neq 0$ dimana $i \in \{1, \ldots h\}$ (Residual belum memenuhi asumsi *white noise*).

Penolakan hipotesis asumsi *white noise* dilakukan menggunakan statistic uji *portmanteau* berikut:

$$Q_h = N^2 \sum_{k=1}^{h} (N-k)^{-1}\, tr[\hat{\Gamma}_{\hat{a}}(k)\, \hat{\Sigma}^{-1} \hat{\Gamma}_{\hat{a}}(k)\, \hat{\Sigma}^{-1}]$$

dimana *autocovarians* matriks lag k pada residual $\hat{a}_t$ didefinisikan sebagai

$$\hat{\Gamma}_{\hat{a}}(k) = N^{-1} \sum_{t=1}^{N-1} \hat{a}_t \hat{a}'_{t+k}$$

dimana $k = 0,1,..h$ dan $\hat{\Gamma}_{\hat{a}}(0) \approx \hat{\Sigma}, \hat{a}_t$ adalah estimasi vektor residual model VAR(p) dengan proses stasioner. Tolak $H_0$ apabila $Q_h > c^2{}_{(m^2(h-p))}$ atau *p-value* < α. Tolak $H_0$ berarti residual belum memenuhi asumsiwhite noise (Box, Jenkins, & Reinsel, 2008).

## 2.13 Pengecekan Asumsi Distribusi Normal

Uji Jarque-Bera merupakan salah satu metode yang sangat populer dalam pengujian *goodness of fit* di bidang ekonomi. Berdasarkan penelitian oleh Jarque dan Bera (1987), uji ini menggunakan pendekatan pengujian berdasarkan nilai *skewness* dan *kurtosis*

$$JB = \frac{n}{6}\left(\sqrt{b_1}\right)^2 + \frac{(b_2 - 3)^2}{4}$$

Hipotesis nol akan ditolak apabila nilai JB lebih besar dibandingkan nilai kritis dari tabel Chi-square pada derajat kebebasan 2, yang mengindikasikan bahwa data tidak mengikuti distribusi normal.

## 2.14 Asumsi Homoskedastisitas Residual

Menurut (Bilondatu et al., 2019), (Fadhly et al., 2023) model *Autoregressive Conditional Heteroscedastic* (ARCH) digunakan untuk mengatasi *error* yang tidak konstan dalam data runtun waktu dan peramalan dengan model ini cukup dilakukan dengan adanya data runtun waktu tunggal sehingga tidak membutuhkan aspek-aspek lain yang dapat mempengaruhi perubahan data runtun waktu. Asumsi dalam metode ini bahwa nilai peramalan di masa depan dipengaruhi oleh kuadrat residual pada periode-periode sebelumnya (Maulana & Lovita, 2021). Bentuk umum dari model ARCH adalah sebagai:

$$\sigma_t^2 = \alpha_0 + \alpha_1 e_{t-1}^2 + \alpha_2 e_{t-2}^2 + \alpha_p e_{y-p}$$

dengan:

$\sigma_t^2$ = Varian pada periode t

$\alpha_0$ = Konstanta

$\alpha_1,..,\alpha_p$ = Parameter ARCH

$e_{t-1}^2$ = Residual pada periode $t - i$ (i = 1,2,…,p)

## 2.15 Pemilihan Model Terbaik

Berdasarkan analisis time series atau analisis data secara umum, beberapa model cukup mewakili data. Terkadang pemilihan model tersebut mudah namun dapat juga sulit. Beberapa kriteria pemilihan model terbaik yang didasarkan residual adalah sebagai berikut(Shumway & Stoffer, 2011):

$$AIC(p) = ln|\hat{\Sigma}_a| + \frac{m(p+n)}{n-m-p-1}$$

Dimana $\hat{\Sigma}_a$ merupakan matriks kovarians, dan n adalah banyak observasi. Pemilihan model terbaik berdasarkan data *out-sample* menggunakan MAPE. MAPE adalah ukuran keakurasian dari nilai data time series pada suatu metode dan biasanya diekspresikan dalam bentuk persen

$$M = \frac{1}{n}\sum_{t=1}^{n}\left|\frac{A_t - F_t}{A_t}\right|$$

dimana $A_t$ adalah nilai sesungguhnya dan $F_t$ adalah nilai hasil peramalan. Selisih antara $A_t$ dan $F_t$ dibagi dengan nilai $A_t$. Nilai absolut dari perhitungan ini kemudian ditambahkan dengan nilai absolut dari setiap poin peramalan (Mynsbrugge, 2010).

# BAB 3
# METODOLOGI

## 3.1 Sumber Data

Data yang digunakan dalam penelitian ini adalah data sekunder yang didapat dari *website* https://www.bps.go.id/id. Data tersebut merupakan data bulanan IT (Indeks Harga yang Diterima Petani) dari sektor Petani Umum periode Januari 2019 – Mei 2025 dari dua provinsi, yaitu NTB dan NTT.

## 3.2 Variabel Penelitian

Variabel yang digunakan dalam penelitian menggunakan analisis VAR sebagai berikut:

1. Indeks Harga yang Diterima Petani (IT) Provinsi NTB periode Januari 2019 – Mei 2025 sebanyak 77 data.
2. Indeks Harga yang Diterima Petani (IT) Provinsi NTT periode Januari 2019 – Mei 2025 sebanyak 77 data.

Struktur data penelitian dini disajikan seperti tabel 3.1 berikut.

**Tabel 3.1** Struktur Data

| t | Periode | $Z_{1,t}$ | $Z_{2,t}$ |
|---|---|---|---|
| 1 | Januari 2019 | $Z_{1,1}$ | $Z_{2,1}$ |
| 2 | Februari 2019 | $Z_{1,2}$ | $Z_{2,2}$ |
| : | : | : | : |
| 77 | Mei 2025 | $Z_{1,77}$ | $Z_{2,77}$ |

Keterangan:

$Z_{1,t}$ : Indeks Harga yang Diterima Petani (IT) Provinsi NTB

$Z_{2,t}$ : Indeks Harga yang Diterima Petani (IT) Provinsi NTT

Data IT tersebut dibagi menjadi dua, yaitu data training dan data testing. Data training digunakan untuk memodelkan yaitu periode Januari 2019 sampai Maret 2024. Sedangkan data testing digunakan untuk mengetahui nilai akurasi peramalan yaitu periode April 2024 sampai Mei 2025.

## 3.3 Metode Analisis Data

Langkah analisis dalam penelitian tentang peramalan Indeks Harga yang Diterima Petani (IT) Provinsi NTB, NTT menggunakan VAR adalah sebagai berikut:

1. Membagi data total sebanyak 77 data menjadi data *in sample* sebanyak 63 data dan data *out sample* seabnyak 14 data.
2. Memeriksa kestasioneran data dalam varians dan *mean* apabila data belum stasioner dalam varians, maka dilakukan transformasi data dan apabila data belum stasioner dalam *mean*, maka perlu dilakukan *diferencing* data.
3. Mengidentifikasi model dengan menggunakan plot MPACF dari data yang telah stasioner dengan nilai AIC terkecil untuk menentukan orde model VAR.
4. Mengestimasi dan menguji parameter model dugaan dengan Least Square.
5. Memeriksa asumsi residual yaitu white noise dengan *portmentau test*, asumsi distribusi normal dengan menggunakan uji distribusi *normal multivariate* dan uji homoskedastisitas residual dengan *ARCH Test*.

6. Pemilihan model terbaik didasarkan pada model VAR dugaan yang memiliki parameter signifikan dan memenuhi asumsi residual.
7. Melakukan forecast untuk Indeks Harga yang Diterima Petani (IT) Provinsi NTB dan NTT.

Diagram alir mendapatkan model VAR selengkapnya disajikan pada gambar 3.1 sebagai berikut

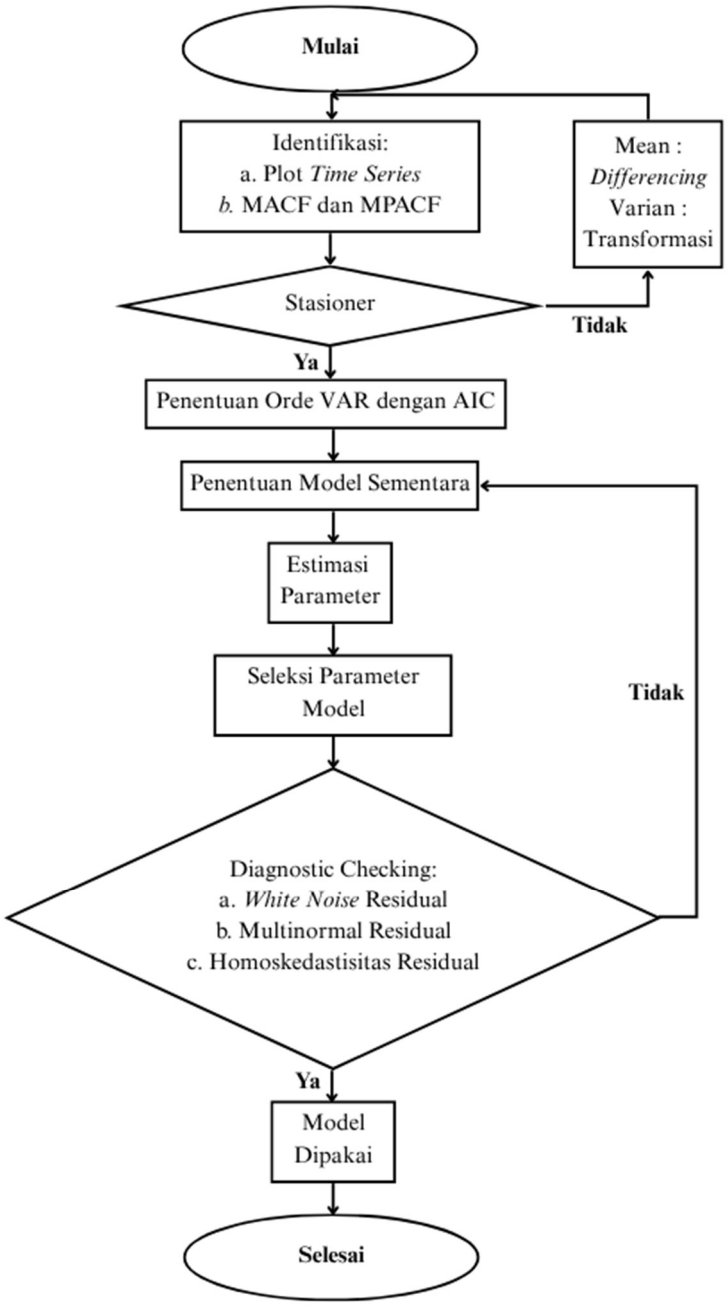


**Gambar 3.1** Diagram Alir Membentuk Model VAR

# BAB 4
# HASIL DAN PEMBAHASAN

## 4.1 Karakteristik Data

Gambaran indeks harga Indeks Harga yang Diterima Petani (IT) dapat diketahui melalui statistika deskriptif. Berikut merupakan karakteristik untuk menggambarkan informasi dari Indeks Harga yang Diterima Petani (IT) Provinsi NTB dan NTT periode Januari 2019 hingga Mei 2025.

**Tabel 4.1** Statistik Deskriptif IT di Dua Provinsi

| Provinsi | Mean | Minimum | Maksimum | Median |
|---|---|---|---|---|
| NTB | 123,77 | 104,41 | 153,16 | 115,96 |
| NTT | 106,73 | 98,94 | 119,7 | 103,78 |

Berdasarkan data yang dianalisis, Indeks Harga yang Diterima Petani (IT) di Provinsi Nusa Tenggara Barat (NTB) menunjukkan rerata yang secara signifikan lebih tinggi, yakni sebesar 123,77, dengan rentang fluktuasi yang cukup lebar, mulai dari nilai minimum 104,41 hingga maksimum 153,16. Nilai median sebesar 115,96 yang berada di bawah rata-rata mengindikasikan adanya kecenderungan distribusi data yang condong ke kanan (right-skewed), mencerminkan potensi terjadinya pergerakan harga yang lebih ekstrem ke arah kenaikan. Sebaliknya, di Provinsi Nusa Tenggara Timur (NTT), rata-rata IT tercatat lebih rendah yaitu sebesar 106,73, namun dengan tingkat stabilitas harga yang relatif lebih tinggi sebagaimana tercermin dari rentang nilai yang sempit, yakni antara 98,94 hingga 119,70, serta nilai median 103,78 yang relatif dekat dengan nilai rata-rata. Pola ini menunjukkan bahwa distribusi harga di NTT lebih terpusat dan cenderung stabil, sehingga memiliki tingkat prediktabilitas yang lebih tinggi dibandingkan NTB.

Pergerakan Indeks Harga yang Diterima Petani (IT) di Provinsi Nusa Tenggara Barat (NTB) periode Januari 2019 - Mei 2025 dapat diketahui melalui bentuk *time series* plot dalam Gambar 4.1.

(a) (b)

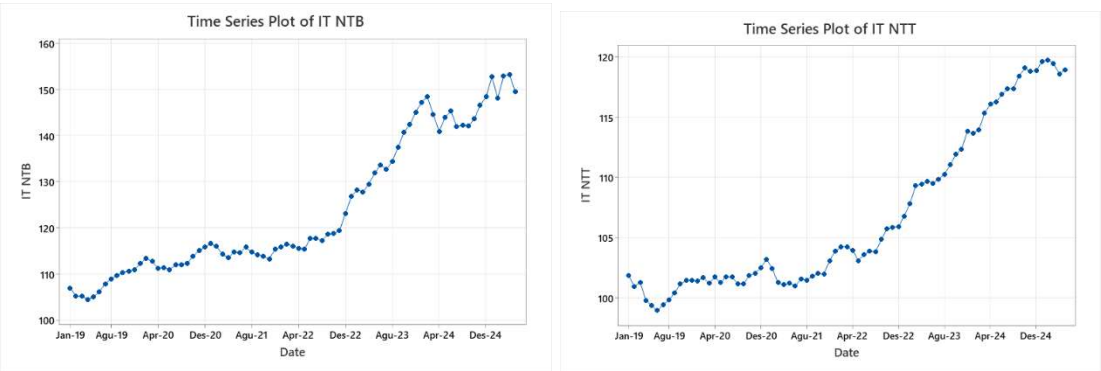


**Gambar 4.1** Time Series Plot (a) NTB, (b) NTT

Berdasarkan Gambar 4.1, terlihat pergerakan data di provinsi NTB dari Januari 2019 hingga Mei 2025, terlihat jelas adanya tren kenaikan yang kuat dan konsisten sepanjang seluruh periode pengamatan. Nilai data di provinsi NTB dimulai pada level yang lebih rendah di awal

tahun 2019 dan secara bertahap, kemudian dengan percepatan yang signifikan mulai sekitar akhir 2022, terus meningkat hingga mencapai level tertinggi pada akhir 2024. Sedangkan pergerakan data di provinsi NTT menunjukkan tren kenaikan yang kuat dan persisten sepanjang periode, dengan percepatan pertumbuhan yang signifikan di dua tahun terakhir. Tidak ada pola musiman yang jelas. variabilitas atau volatilitas data di Provinsi NTT tampak relatif lebih konstan di sekitar tren Adanya pergerakan searah pada beberapa periode juga menandakan potensi interdependensi antara kedua variabel, sehingga diperlukan uji pengecekan stasioneritas data lebih lanjut sebelum melakukan pemodelan dengan metode VAR.

## 4.2 Identifikasi Hubungan Kausalitas

Uji Kausalitas Granger digunakan untuk melihat apakah dua variabel time series saling memengaruhi. Uji ini bekerja dengan cara memeriksa apakah data masa lalu dari satu variabel dapat membantu memprediksi nilai variabel yang lain. Proses ini menunjukkan arah hubungan kausal antarvariabel. Hipotesis dan metode pengujiannya disajikan di bawah ini.

$H_0 : f_{21} = 0$ ($Z_{1t}$ bukan penyebab $Z_{2t}$),
$H_1 : f_{21} \neq 0$ ($Z_{1t}$ penyebab $Z_{2t}$).

**Tabel 4.2** Hasil Uji Kausalitas antar Variabel

| Variabel ($Z_{1t}$) | Variabel ($Z_{2t}$) | Chi-sq | P-Value | Keputusan |
|---|---|---|---|---|
| IT_NTB | IT_NTT | 0,00 | 0,9903 | Gagal Tolak $H_0$ |
| IT_NTT | IT_NTB | 7,82 | 0,0052 | Tolak $H_0$ |

Berdasarkan Tabel 4.2, dapat diketahui variabel IT_NTT terbukti memiliki hubungan kausalitas yang signifikan terhadap IT_NTB, yang ditunjukkan oleh nilai P-Value sebesar 0,0052 (< 0,05). Sebaliknya, tidak ditemukan adanya hubungan kausalitas dari IT_NTB terhadap IT_NTT, karena nilai P-Value sebesar 0,9903 tidak signifikan. Dengan demikian, dapat disimpulkan bahwa IT_NTT memengaruhi IT_NTB, namun tidak berlaku sebaliknya.

## 4.3 Identifikasi Stationer pada Data Time Series

Dalam pemodelan *Vector Autoregressive* (VAR), asumsi stasioneritas data menjadi syarat utama yang menuntut rata-rata dan varians data harus konstan sepanjang waktu tanpa menunjukkan tren. Jika kondisi ini tidak terpenuhi, hasil dari estimasi model berpotensi menjadi bias dan tidak valid. Oleh karena itu, untuk memastikan keandalan hasil analisis, pelaksanaan uji stasioneritas merupakan tahap wajib yang harus didahulukan sebelum pemodelan VAR dilakukan.

### 4.3.1 Stationer dalam Varians

Untuk mengevaluasi kestasioneran data dalam varians, digunakan metode Transformasi Box-Cox. Setelah dilakukan pengujian didapatkan kedua variabel belum memenuhi asumsi stationer dalam varians. Maka perlu dilakukan transformasi Box-Cox sesuai dengan nilai rounded value yang didapatkan. Berikut merupakan hasil output setelah dilakukan transformasi Box-Cox. Hasil dari proses identifikasi tersebut selanjutnya disajikan secara ringkas dalam tabel berikut ini.

**Tabel 4.3** Identifikasi Stationer dalam Varians Setelah Transformasi

| Variabel | Lower CL | Upper CL | Rounded Value |
|---|---|---|---|
| IT_NTB | -1,72 | 3,89 | 1,00 |
| IT_NTT | -0,01 | 2,10 | 1,00 |

Berdasarkan Tabel 4.3, terlihat bahwa nilai *rounded value* pada masing masing variabel adalah 1 atau dapat dikatakan bahwa setelah ditransformasi, kedua variabel sudah memenuhi asumsi stationer dalam varians sehingga dapat untuk dilakukan analisis lanjutan.

### 4.3.2 Stationer dalam Mean

Untuk mengidentifikasi kestasioneran data dalam mean, maka dilakukan analisis *Matrix Autocorrelation Function* (MACF) . Hasil yang disajikan di bawah ini merupakan output dari analisis MACF pada data asli sebelum dilakukan proses *differencing*.

| Schematic Representation of Correlations | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Name/Lag | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
| IT_NTB | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ |
| IT_NTT | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ | ++ |
| + is > 2*std error, - is < -2*std error, . is between | | | | | | | | | | | |

**Gambar 4.2** MACF Sebelum Differencing

Visualisasi pada Gambar 4.2 menunjukkan bahwa nilai MACF tetap signifikan di seluruh lag, yang mengonfirmasi kondisi data yang tidak stasioner dalam mean. Sebagai tindak lanjut, dilakukan proses *differencing* sebanyak satu kali pada data untuk mencapai stasioneritas. Untuk mengevaluasi efektivitas proses tersebut, selanjutnya dilakukan Uji Dickey-Fuller, di mana hipotesis dan tabel hasilnya dapat dilihat sebagai berikut.

$H_0 : \delta = 1$ (data belum stationer dalam mean)
$H_1 : \delta < 1$ (data telah stationer dalam mean)

**Tabel 4.4** Hasil Stationer dalam Mean setelah Differencing 1

| Variabel | Type | Tau | Pr < Tau | Keputusan |
|---|---|---|---|---|
| IT_NTB | *Zero Mean* | -3,70 | 0,0004 | Tolak $H_0$ |
| | *Single Mean* | -4.35 | 0,0009 | Tolak $H_0$ |
| | *Trend* | -4,46 | 0,0037 | Tolak $H_0$ |
| IT_NTT | *Zero Mean* | -3,37 | 0,0011 | Tolak $H_0$ |
| | *Single Mean* | -3,94 | 0,0031 | Tolak $H_0$ |
| | *Trend* | -4,83 | 0,0012 | Tolak $H_0$ |

Berdasarkan Tabel 4.4, dapat dilihat bahwa hipotesis nol ditolak untuk kedua variabel, IT NTB dan IT NTT, pada ketiga model yang diuji. Keputusan untuk menolak $H_0$ ini mengonfirmasi bahwa kedua variabel tersebut telah memenuhi asumsi stasioneritas dalam rata-rata (mean). Data terbukti stasioner baik ketika dianalisis menggunakan model tanpa konstanta (*Zero Mean*), model dengan konstanta (*Single Mean*), maupun model yang menyertakan komponen tren (*Trend*).

## 4.4 Pemilihan Model VAR Sementara

Pemilihan model sementara untuk data yang telah terbukti stasioner didasarkan pada nilai *Akaike's Information Criterion* (AIC) yang terkecil. Perhitungan nilai AIC tersebut dilakukan pada data yang telah ditransformasi dan mengalami *differencing* sebanyak satu kali, di mana hasilnya dirangkum dalam tabel berikut.

**Tabel 4.5** AIC Model VAR

| Lag | AIC |
|---|---|
| 0 | -27,28 |
| 1 | -29,71 |
| 2 | -28,60 |
| 3 | -22,15 |
| 4 | -16,49 |
| 5 | -9,50 |
| 6 | -3,81 |
| 7 | 2,75 |
| 8 | 9,29 |
| 9 | 16,13 |
| 10 | 21,63 |

Hasil pada Tabel 4.5 mengindikasikan bahwa lag ke-1 menghasilkan nilai *Akaike's Information Criterion* (AIC) terendah, yaitu -29,71 Temuan ini menetapkan VAR(1) sebagai model tentatif terbaik untuk digunakan dalam penelitian ini.

## 4.5 Estimasi Parameter Model VAR

Uji signifikansi parameter diterapkan pada model VARIMA(1,1,0) untuk mengevaluasi apakah setiap koefisien estimasi memiliki kontribusi yang signifikan secara statistik. Spesifikasi model ini merupakan hasil dari kebutuhan *differencing* data sebanyak satu kali demi mencapai stasioneritas dan penentuan lag optimal sebanyak tiga yang didasarkan pada nilai kriteria informasi Akaike (AIC). Model yang terbentuk dengan spesifikasi tersebut menghasilkan 4 parameter estimasi yang akan diuji, seperti yang dirinci di bawah ini.

**Tabel 4.6** Estimasi Parameter model VAR(1)

| Variabel | Parameter | Estimasi | S.e | t Hitung | P-Val | Variabel |
|---|---|---|---|---|---|---|
| IT_NTB | AR(1,1,1) | 0,5050 | 0,1431 | 3.52 | 0,0008 | IT_NTB(t-1) |
| | AR(1,1,2) | 0,0040 | 0,3317 | 0,01 | 0,9904 | IT_NTT(t-1) |
| IT_NTT | AR(1,2,1) | 0,1718 | 0,0614 | -1 | 0,0070 | IT_NTB(t-1) |
| | AR(1,2,2) | 0,1052 | 0,1423 | -0,69 | 0,4625 | IT_NTT(t-1) |

Berdasarkan hasil yang ditampilkan dalam Tabel 4.6 , dapat diketahui bahwa tidak semua parameter dalam model bersifat signifikan secara statistik. Hal ini terlihat dari adanya beberapa nilai P-Value yang lebih besar dari tingkat signifikansi $\alpha = 0,05$. Oleh karena itu, diperlukan proses pembatasan (*restrict*) terhadap parameter-parameter yang tidak signifikan tersebut untuk memperoleh model VAR yang lebih efisien. Estimasi dan uji signifikansi parameter setelah dilakukan restriksi disajikan pada bagian berikut.

**Tabel 4.7** Estimasi Parameter model VAR(1) setelah *restrict*

| Variabel | Parameter | Estimasi | S.e | t Hitung | P-Val | Variabel |
|---|---|---|---|---|---|---|
| IT_NTB | AR(1,1,1) | 0,5050 | 0,1193 | 4,23 | 0,0001 | IT_NTB(t-1) |
| IT_NTT | AR(1,2,1) | 0,1969 | 0,0512 | 3,85 | 0,0003 | IT_NTB(t-1) |

Berdasarkan hasil estimasi pada Tabel 4.7, diperoleh informasi bahwa kedua parameter yang tersisa yaitu AR(1,1,1) dan AR(1,2,1) semuanya signifikan secara statistik terhadap model. Signifikansi ini dibuktikan oleh nilai P-Value untuk setiap parameter yang lebih kecil dari tingkat signifikansi $\alpha = 0,05$, yang berarti parameter-parameter tersebut memiliki kontribusi nyata dalam menjelaskan hubungan dinamis antar variabel dalam sistem VAR. Sehingga dapat disimpulkan bahwa variabel IT_NTB dipengaruhi secara signifikan oleh nilai dirinya sendiri pada lag ke-1, sedangkan variabel IT_NTT juga dipengaruhi secara signifikan nilai dari IT_NTB pada lag ke-1. Hal ini menunjukkan adanya keterkaitan antara indeks tani NTB dan NTT, di mana perubahan pada Indeks Tani NTB di masa lalu memiliki pengaruh terhadap pergerakan Indeks Tani NTT.

## 4.6 Pemeriksaan Asumsi Residual

Validasi terhadap model VAR(1) yang telah diestimasi dilakukan dengan memeriksa apakah residualnya telah memenuhi asumsi-asumsi diagnostik yang disyaratkan. Untuk tujuan ini, serangkaian pengujian diterapkan pada residual model, yang mencakup uji *white noise* untuk autokorelasi, uji normalitas multivariat, dan uji ARCH untuk heteroskedastisitas.

### 4.6.1 Uji White Noise

Penerapan Ljung-Box Test dilakukan untuk menguji hipotesis *white noise*, yaitu memastikan residual dari model VAR(1) tidak lagi mengandung autokorelasi dan bersifat acak. Hasil pengujian pada beberapa lag residual tersebut ditampilkan dalam tabel berikut.

**Tabel 4.8** Pengujian White Noise variabel IT_NTB

| Lag | Chi-square | DF | P-value |
|---|---|---|---|
| 6 | 4.54 | 6 | 0.6038 |
| 12 | 14.54 | 12 | 0.2678 |
| 18 | 21.21 | 18 | 0.2688 |
| 24 | 27.92 | 24 | 0.2635 |

**Tabel 4.9** Pengujian White Noise variabel IT_NTT

| Lag | Chi-square | DF | P-value |
|---|---|---|---|
| 6 | 3.28 | 6 | 0.7733 |
| 12 | 9.21 | 12 | 0.6846 |
| 18 | 16.97 | 18 | 0.5253 |
| 24 | 22.93 | 24 | 0.5239 |

Hasil pengujian Ljung-Box menunjukkan bahwa nilai p-value pada semua lag yang dievaluasi secara konsisten berada di atas tingkat signifikansi 0,05. Temuan ini mengindikasikan tidak adanya bukti autokorelasi yang signifikan secara statistik dalam residual model. Oleh karena itu, dapat disimpulkan bahwa sisaan (residual) dari model VAR(1) yang diestimasi telah memenuhi asumsi *white noise*.

### 4.6.2 Uji Normalitas

Pengujian asumsi normalitas merupakan salah satu tahap diagnostik krusial yang bertujuan untuk mengevaluasi apakah sisaan (residual) dari model telah berdistribusi secara normal. Untuk tujuan ini, metode yang digunakan adalah Uji Jarque-Bera, yang dapat diidentifikasi dari penggunaan statistik Chi-Square pada tabel hasil. Berikut adalah hasil dari Uji Jarque-Bera yang diterapkan pada residual model.

**Tabel 4.10** Pengujian Normalitas menggunakan Jarque-Bera

| Variabel | Chi-Sq | P-value |
|---|---|---|
| IT_NTB | 3.39 | 0,1833 |
| IT_NTT | 1.09 | 0,5800 |

Berdasarkan hasil pengujian normalitas menggunakan metode Jarque-Bera, nilai P-value untuk residual dari kedua variabel, IT_NTB dan IT_NTT, tidak signifikan secara statistik. Sehingga dapat disimpulkan bahwa sisaan (residual) dari kedua variabel tersebut telah berdistribusi normal, sehingga asumsi normalitas untuk model VAR(1) yang digunakan telah terpenuhi.

### 4.6.3 Uji Heteroskedastisitas

Pengujian untuk mendeteksi ada atau tidaknya gejala heteroskedastisitas bersyarat, atau yang dikenal sebagai efek ARCH, pada residual model dilakukan dengan menerapkan Uji ARCH-LM (*Lagrange Multiplier*). Hasil pengujiannya disajikan sebagai berikut.

**Tabel 4.11** Pengujian Heteroskedastisitas menggunakan ARCH-LM

| Variabel | F Value | P-value |
|---|---|---|
| IT_NTB | 0,00 | 0,9995 |
| IT_NTT | 0,24 | 0,6234 |

Hasil pengujian heteroskedastisitas menggunakan metode ARCH-LM menunjukkan tidak adanya efek ARCH yang signifikan pada residual untuk kedua variabel, IT_NTB dan IT_NTT. Karena nilai P-value keduanya berada jauh di atas tingkat signifikansi 0,05, dapat disimpulkan bahwa asumsi homoskedastisitas pada model VAR( telah terpenuhi.

## 4.7 Model Terbaik

Setelah model VAR(1) telah memenuhi semua asumsi residual, maka langkah selanjutnya adalah melakukan estimasi terhadap parameter-parameter model. Koefisien model yang didapatkan dari VAR(1) setelah dilakukan restriksi ditunjukkan pada matriks berikut

$$\Phi_1 = \begin{bmatrix} 0{,}505 & 0{,}000 \\ 0{,}197 & 0{,}000 \end{bmatrix}$$

Sehingga, persamaan model VAR(1) setelah dilakukan restriksi dapat dituliskan sebagai berikut.

$$IT_NTB_t = 0{,}505 \cdot IT_NTB_{t-1} + \varepsilon_{1t}$$
$$IT_NTT_t = 0{,}197 \cdot IT_NTB_{t-1} + \varepsilon_{2t}$$

Secara keseluruhan, model ini mengindikasikan adanya hubungan pengaruh yang bersifat satu arah, di mana variabel IT_NTB berperan sebagai faktor penggerak utama. Nilai IT_NTB pada bulan sebelumnya terbukti secara positif memengaruhi nilainya sendiri sekaligus nilai IT_NTT di bulan ini. Sebaliknya, variabel IT_NTT cenderung berperan sebagai pengikut, karena pergerakannya lebih banyak dipengaruhi oleh kondisi IT_NTB di masa lalu, sementara nilai historisnya sendiri tidak menunjukkan pengaruh yang signifikan dalam model akhir.

Evaluasi diagnostik terhadap residual model menunjukkan bahwa seluruh asumsi utama telah terpenuhi. Secara spesifik, residual terbukti bersifat *white noise* (bebas autokorelasi), mengikuti distribusi normal multivariat, dan tidak mengandung gejala heteroskedastisitas bersyarat (efek ARCH). Terpenuhinya semua asumsi ini mengindikasikan bahwa model yang diestimasi stabil dan valid untuk digunakan dalam analisis selanjutnya seperti peramalan.

## 4.8 Peramalan dan Evaluasi Akurasi Prediksi

Setelah model final diperoleh dan divalidasi, langkah berikutnya adalah mengevaluasi tingkat kecocokan model (*goodness-of-fit*) terhadap data historis. Untuk tujuan ini, dilakukan peramalan kembali pada periode data train (*in-sample forecast*) guna membandingkan seberapa dekat nilai prediksi yang dihasilkan model dengan nilai data aktual yang digunakan untuk membangunnya. Berikut adalah hasil prediksi data aktual untuk periode April 2024 hingga Mei 2024.

**Tabel 4.12** Peramalan Indeks Tani NTB dn NTT

| Periode | IT_NTB | IT_NTT |
|---|---|---|
| April 2024 | 142,495 | 114,544 |
| Mei 2024 | 141,503 | 114,157 |
| Juni 2024 | 141,002 | 113,962 |
| Juli 2024 | 140,749 | 113,863 |
| Agustus 2024 | 140,621 | 113,813 |
| September 2024 | 140,557 | 113,788 |
| Oktober 2024 | 140,524 | 113,775 |
| November 2024 | 140,508 | 113,769 |
| Desember 2024 | 140,499 | 113,765 |
| Januari 2025 | 140,495 | 113,764 |
| Februari 2025 | 140,493 | 113,763 |
| Maret 2025 | 140,492 | 113,763 |
| April 2025 | 140,491 | 113,762 |
| Mei 2025 | 140,491 | 113,762 |

Berdasarkan peramalan tersebut, berikut adalah plot time series dari prediksi dan data aktual dari kedua variabel dari periode April 2024 hingga Mei 2025.

(a) (b)

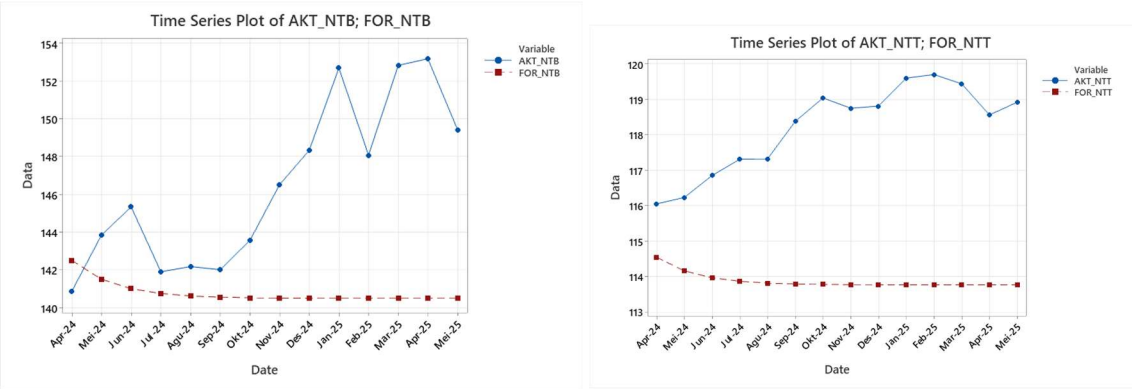


**Gambar 4.3** Plot Time Series Hasil Peramalan model VAR(1) (a) IT_NTB, (b) IT_NTT

Terlihat bahwa baik untuk IT_NTB maupun IT_NTT, model menghasilkan prediksi yang cenderung datar dan stabil setelah periode awal. Perilaku prediksi yang statis ini sangat kontras dengan data aktualnya, yang pada kenyataannya menunjukkan tren kenaikan yang kuat serta fluktuasi yang jauh lebih dinamis.

Kemampuan prediktif model diuji melalui peramalan di luar periode data latih (*out-of-sample forecast*) untuk 14 bulan ke depan. Akurasi dari peramalan ini dievaluasi secara kuantitatif menggunakan dua metrik kesalahan, yaitu *Mean Absolute Percentage Error* (MAPE) dan *Root Mean Squared Error* (RMSE). Hasil perhitungan kedua metrik tersebut disajikan dalam tabel berikut.

**Tabel 4.13** Evaluasi MAPE model terbaik VAR(1)

| Variabel | MAPE (%) | RMSE |
|---|---|---|
| IT_NTB | 3,967 | 7,251 |
| IT_NTT | 3,657 | 4,546 |

Berdasarkan Tabel 4.14, evaluasi akurasi peramalan untuk model VAR(1) menunjukkan hasil yang secara numerik sangat baik. Untuk variabel IT_NTB, diperoleh nilai MAPE sebesar 3,96% dan RMSE sebesar 7,25, sedangkan untuk variabel IT_NTT, nilai MAPE adalah 3,65% dengan RMSE sebesar 4,54. Menurut pedoman umum, nilai MAPE yang berada di bawah 10% mengindikasikan bahwa model memiliki tingkat akurasi peramalan yang sangat tinggi. Nilai RMSE juga menyajikan magnitudo rata-rata kesalahan prediksi dalam unit data asli.

Akurasi yang sangat tinggi ini tampak kontras dengan bukti visual dari plot peramalan sebelumnya, yang menunjukkan adanya divergensi signifikan antara nilai prediksi dan nilai aktualnya (*out-of-sample*. Nilai MAPE/RMSE yang rendah pada data latih lebih mengukur tingkat kecocokan model (*goodness-of-fit*) terhadap data historis, dan tidak selalu mencerminkan kemampuan prediksi (*predictive power*) sesungguhnya di masa depan. Oleh karena itu, meskipun angka-angka ini menunjukkan model sangat cocok dengan data yang digunakannya, evaluasi visual sebelumnya memberikan gambaran yang lebih realistis mengenai tantangan model ini dalam melakukan peramalan ke depan.

# BAB 5 KESIMPULAN DAN SARAN

## 5.1 Kesimpulan

Berdasarkan hasil analisis peramalan Indeks Harga yang Diterima Petani (IT) di Provinsi Nusa Tenggara Barat (NTB) dan Nusa Tenggara Timur (NTT) menggunakan metode Vector Autoregressive (VAR), dapat disimpulkan beberapa hal sebagai berikut:

1. Model terbaik yang terbentuk berdasarkan kriteria Akaike Information Criterion (AIC) adalah VAR(1) dengan spesifikasi differencing satu kali untuk mencapai kestasioneran data. Model ini dipilih karena memiliki nilai AIC paling rendah dibandingkan model lain dengan lag yang berbeda.
2. Hasil uji kausalitas Granger menunjukkan adanya hubungan kausalitas satu arah, yaitu dari IT_NTT terhadap IT_NTB secara signifikan, sedangkan sebaliknya tidak terbukti signifikan. Hal ini mengindikasikan bahwa pergerakan harga hasil pertanian di Provinsi NTT memiliki pengaruh terhadap pergerakan harga di Provinsi NTB, namun tidak berlaku sebaliknya.
3. Model VAR(1) hasil estimasi menunjukkan bahwa nilai IT_NTB dipengaruhi secara signifikan oleh nilai dirinya sendiri di periode sebelumnya, dan nilai IT_NTT dipengaruhi oleh nilai IT_NTB di periode sebelumnya. Nilai historis IT_NTT sendiri tidak berpengaruh terhadap IT_NTT di periode berikutnya.
4. Berdasarkan hasil diagnosis model, residual dari model VAR(1) telah memenuhi semua asumsi yang dipersyaratkan yaitu white noise, normalitas multivariat, dan homoskedastisitas residual. Hal ini menunjukkan bahwa model bersifat stabil dan valid untuk digunakan dalam peramalan.
5. Hasil peramalan out-of-sample untuk periode Mei 2024 hingga Mei 2025 menunjukkan nilai *Mean Absolute Percentage Error* (MAPE) sebesar 3,96% untuk IT_NTB dan 3,65% untuk IT_NTT, yang berada di bawah ambang batas 10%, sehingga dikategorikan memiliki akurasi peramalan yang sangat baik.
6. Meskipun demikian, hasil plot peramalan menunjukkan bahwa prediksi cenderung datar setelah periode tertentu dan kurang mampu menangkap tren kenaikan aktual secara optimal. Hal ini menandakan bahwa meskipun model memiliki *goodness-of-fit* yang baik terhadap data historis, kemampuan prediktif untuk periode mendatang masih perlu ditingkatkan.

## 5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran yang dapat diberikan untuk pengembangan studi selanjutnya adalah sebagai berikut:

1. Menambahkan variabel eksternal (exogenous variables) seperti harga komoditas global, biaya produksi, curah hujan, atau faktor musiman untuk memperkaya model multivariat, sehingga mampu menangkap dinamika harga yang lebih kompleks di sektor pertanian.
2. Menggunakan metode peramalan lain seperti VARMA, VECM (jika ditemukan kointegrasi antar variabel), atau model nonlinier seperti Neural Network Autoregressive (NNAR) dan LSTM untuk membandingkan performa dan meningkatkan kemampuan prediksi jangka panjang.
3. Menggunakan periode data yang lebih panjang atau frekuensi data yang lebih tinggi (misal mingguan atau harian) untuk meningkatkan kestabilan estimasi model dan validitas statistik, khususnya pada saat tren harga menunjukkan fluktuasi yang tajam.

4. Melakukan cross-validation atau rolling forecasting origin untuk menguji robust-nya model dalam berbagai skenario data aktual di masa depan.

# DAFTAR PUSTAKA


Box, G. E., Jenkins, G. M., & Reinsel, G. C. (2008). Time series Analysis Forecasting and Control. Canada: John Wiley & Sons, Inc

Bilondatu, R. N., Nurwan, & Isa, D. R. (2019). *Model ARCH (1) dan GARCH (1,1) pada Peramalan Harga Saham PT. Cowell Development Tbk.*

C. M. Jarque dan A. K. Bera. ”A Test for Normality with High Uniform Power,” *Computational Statistics dan Data Analysis,* vol. 40, no. 3, pp. 435-445. 2002.

Enders, W. (1995). Applied Econometric Time series. Canada: John Wiley & Sons, Inc.

Fadhly, F. Z., Muziatun, Manan, N. A., Acesta, A., & Solihat, D. (2023). An academic writing model: Lessons learned from experienced writers. *Indonesian Journal of Applied Linguistics*, *12*(3), 870–880. https://doi.org/10.17509/IJAL.V12I3.44952

Johnson, R. A., & Wichern, D. W. (2007). Applied Multivariate Statistical Analysis. United States of America: Pearson Education, Inc.

J. V. Mynsbrugge, "Bidding Strategies Using Price Based Unit Commitment in a Deregulated Power Market," K. U. Leuven, 2010.

Makridakis, S., & Hibon, M. (2000). The M3-Competition: Results, Conclusions and Implications. International Journal of Forcasting, 16, 451-476.

Maulana, Y., & Lovita, N. (2021). Analisis Volatilitas pada Hubungan Dinamis antara Nilai Tukar, Tingkat Suku Bunga dan IHSG. Indonesian Journal of Strategic Management, 4(2).

Shumway, R. H., & Stoffer, D. S. (2011). Time Series Analysis and its Applications. New York: Springer Science Business Media.

Wei, W.W.S. 2006. Time Series Analysis Univariate and Multivariate Method. Canada : Addison Wesley Publishing Company, Inc.

# LAMPIRAN

| | A | B | C | D |
|---|---|---|---|---|
| 1 | NTB_IN | NTT_IN | NTB_OUT | NTT_OUT |
| 2 | 106,59 | 101,81 | 110,37 | 116,05 |
| 3 | 105,14 | 100,81 | 113,04 | 116,23 |
| 4 | 105,03 | 101,26 | 115,33 | 116,35 |
| 5 | 104,61 | 99,77 | 111,9 | 117,31 |
| 6 | 104,91 | 99,34 | 112,17 | 117,32 |
| 7 | 106,12 | 99,84 | 112,01 | 118,38 |
| 8 | 107,82 | 99,38 | 113,16 | 118,04 |
| 9 | 108,82 | 99,75 | 106,6 | 118,75 |
| 10 | 109,86 | 100,39 | 118,32 | 118,81 |
| 11 | 110,2 | 101,11 | 112,87 | 119,8 |
| 12 | 110,8 | 101,2 | 118,06 | 119,7 |
| 13 | 110,81 | 101,2 | 112,81 | 119,44 |
| 14 | 112,24 | 101,39 | 113,16 | 118,66 |
| 15 | 113,32 | 101,86 | 109,11 | 118,92 |
| 16 | 112,87 | 101,19 | | |
| 17 | 111,16 | 101,7 | | |
| 18 | 111,32 | 101,26 | | |
| 19 | 110,89 | 101,74 | | |
| 20 | 111,93 | 101,7 | | |
| 21 | 112 | 101,16 | | |
| 22 | 112,26 | 101,11 | | |
| 23 | 113,8 | 101,83 | | |
| 24 | 114,98 | 101,89 | | |
| 25 | 116,72 | 102,46 | | |
| 26 | 116,09 | 103,17 | | |
| 27 | 116,93 | 102,63 | | |
| 28 | 114,24 | 101,23 | | |
| 29 | 113,61 | 101,06 | | |
| 30 | 114,74 | 101,2 | | |
| 31 | 114,52 | 100,84 | | |
| 32 | 116,72 | 101,53 | | |
| 33 | 114,86 | 101,46 | | |
| 34 | 114,06 | 101,75 | | |
| 35 | 113,8 | 102 | | |
| 36 | 113,17 | 101,86 | | |
| 37 | 116,31 | 103,07 | | |
| 38 | 116,72 | 103,87 | | |
| 39 | 116,16 | 104,19 | | |
| 40 | 116,96 | 104,23 | | |
| 41 | 116,51 | 103,83 | | |
| 42 | 116,32 | 103,06 | | |
| 43 | 117,58 | 103,67 | | |
| 44 | 117,86 | 103,86 | | |
| 45 | 117,18 | 103,78 | | |
| 46 | 118,16 | 104,82 | | |
| 47 | 118,7 | 106,89 | | |
| 48 | 119,36 | 106,84 | | |
| 49 | 123 | 106,87 | | |
| 50 | 126,72 | 106,77 | | |
| 51 | 129,17 | 107,8 | | |
| 52 | 127,73 | 109,29 | | |
| 53 | 129,16 | 109,4 | | |
| 54 | 131,8 | 109,86 | | |
| 55 | 133,83 | 109,18 | | |
| 56 | 132,58 | 109,83 | | |
| 57 | 134,31 | 110,24 | | |
| 58 | 137,06 | 111 | | |
| 59 | 140,86 | 111,82 | | |
| 60 | 142,33 | 112,31 | | |
| 61 | 146 | 113,82 | | |
| 62 | 147,2 | 113,82 | | |
| 63 | 148,36 | 113,83 | | |
| 64 | 144,06 | 115,31 | | |
| 65 | 160,870 | 116,050 | | |
| 66 | 163,010 | 116,230 | | |
| 67 | 165,330 | 116,350 | | |
| 68 | 161,860 | 117,310 | | |
| 69 | 162,170 | 117,320 | | |
| 70 | 162,010 | 118,380 | | |
| 71 | 163,660 | 118,010 | | |
| 72 | 166,660 | 118,750 | | |
| 73 | 168,320 | 118,810 | | |
| 74 | 162,870 | 119,860 | | |
| 75 | 163,060 | 119,700 | | |
| 76 | 162,810 | 119,410 | | |
| 77 | 163,180 | 119,160 | | |
| 78 | 169,610 | 119,920 | | |

```
proc statespace data=IMPORT;
var IT_NTB(1) IT_NTT(1);
run;
proc varmax data =IMPORT;
model IT_NTB IT_NTT/ p=1 dftest dify(1) noint
method = ls print=(corry parcoef pcorr pcancorr diagnose roots);
    /* Uji Granger Causality */
    causal group1=(IT_NTB) group2=(IT_NTT);
    causal group1=(IT_NTT) group2=(IT_NTB);
restrict AR(1,1,2), AR(1,2,2);
output lead = 14 out = hasil;
run;
proc print data = hasil;
run;

/* Uji White Noise dengan Ljung-Box untuk masing-masing residual */
proc arima data=hasil;
   identify var=RES1 nlag=24;
run;
proc arima data=hasil;
   identify var=RES2 nlag=24;
run;
```

| Granger-Causality Wald Test | | | |
|---|---|---|---|
| **Test** | **DF** | **Chi-Square** | **Pr > ChiSq** |
| **1** | 1 | 0.00 | 0.9903 |
| **2** | 1 | 7.82 | 0.0052 |

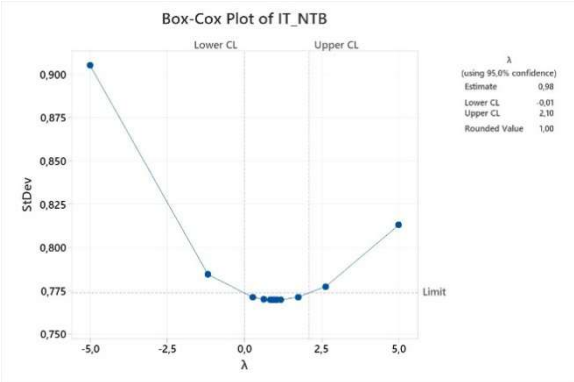


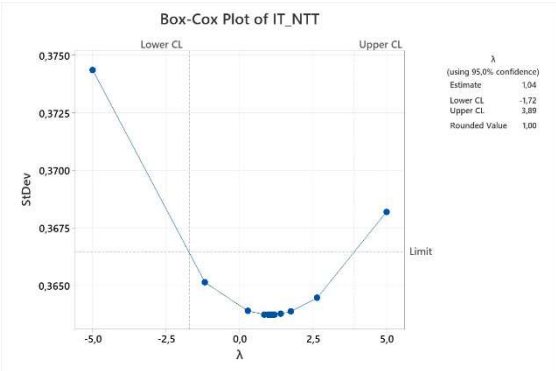


| Dickey-Fuller Unit Root Tests | | | | | |
|---|---|---|---|---|---|
| Variable | Type | Rho | Pr < Rho | Tau | Pr < Tau |
| IT_NTB | Zero Mean | -32.32 | <.0001 | -3.70 | 0.0004 |
| | Single Mean | -48.33 | 0.0006 | -4.35 | 0.0009 |
| | Trend | -60.63 | 0.0001 | -4.46 | 0.0037 |
| IT_NTT | Zero Mean | -26.27 | <.0001 | -3.37 | 0.0011 |
| | Single Mean | -34.67 | 0.0006 | -3.94 | 0.0031 |
| | Trend | -50.93 | 0.0001 | -4.83 | 0.0012 |

| Information Criterion for Autoregressive Models | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| Lag=0 | Lag=1 | Lag=2 | Lag=3 | Lag=4 | Lag=5 | Lag=6 | Lag=7 | Lag=8 | Lag=9 | Lag=10 |
| -27.2883 | -29.7155 | -28.6008 | -22.1517 | -16.4976 | -9.50813 | -3.8143 | 2.758589 | 9.29887 | 16.13418 | 21.63419 |

| Model Parameter Estimates | | | | | | |
|---|---|---|---|---|---|---|
| Equation | Parameter | Estimate | Standard Error | t Value | Pr > \|t\| | Variable |
| IT_NTB | AR1_1_1 | 0.50407 | 0.14319 | 3.52 | 0.0008 | IT_NTB(t-1) |
| | AR1_1_2 | 0.00402 | 0.33175 | 0.01 | 0.9904 | IT_NTT(t-1) |
| IT_NTT | AR1_2_1 | 0.17184 | 0.06144 | 2.80 | 0.0070 | IT_NTB(t-1) |
| | AR1_2_2 | 0.10528 | 0.14235 | 0.74 | 0.4625 | IT_NTT(t-1) |

| Model Parameter Estimates | | | | | | |
|---|---|---|---|---|---|---|
| Equation | Parameter | Estimate | Standard Error | t Value | Pr > \|t\| | Variable |
| IT_NTB | AR1_1_1 | 0.50503 | 0.11935 | 4.23 | 0.0001 | IT_NTB(t-1) |
| | AR1_1_2 | 0.00000 | 0.00000 | | | IT_NTT(t-1) |
| IT_NTT | AR1_2_1 | 0.19695 | 0.05121 | 3.85 | 0.0003 | IT_NTB(t-1) |
| | AR1_2_2 | -0.00000 | 0.00000 | | | IT_NTT(t-1) |

| Autocorrelation Check for White Noise | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| To Lag | Chi-Square | DF | Pr > ChiSq | Autocorrelations | | | | | |
| 6 | 4.54 | 6 | 0.6038 | -0.032 | -0.142 | -0.116 | 0.158 | -0.023 | -0.089 |
| 12 | 14.54 | 12 | 0.2678 | -0.038 | 0.152 | -0.008 | -0.164 | 0.055 | 0.276 |
| 18 | 21.21 | 18 | 0.2688 | -0.076 | -0.064 | -0.241 | 0.063 | 0.036 | -0.081 |
| 24 | 27.92 | 24 | 0.2635 | 0.024 | 0.047 | -0.211 | -0.069 | 0.126 | 0.031 |

| Autocorrelation Check for White Noise | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| To Lag | Chi-Square | DF | Pr > ChiSq | Autocorrelations | | | | | |
| 6 | 3.28 | 6 | 0.7733 | -0.047 | -0.072 | 0.015 | -0.153 | -0.095 | 0.091 |
| 12 | 9.21 | 12 | 0.6846 | 0.070 | -0.057 | 0.082 | -0.224 | 0.109 | 0.047 |
| 18 | 16.97 | 18 | 0.5253 | 0.118 | 0.141 | 0.182 | -0.154 | -0.050 | -0.012 |
| 24 | 22.93 | 24 | 0.5239 | -0.209 | 0.108 | 0.044 | 0.081 | 0.021 | -0.007 |

| Univariate Model White Noise Diagnostics | | | | | |
|---|---|---|---|---|---|
| Variable | Durbin Watson | Normality | | ARCH | |
| | | Chi-Square | Pr > ChiSq | F Value | Pr > F |
| IT_NTB | 1.73920 | 3.39 | 0.1833 | 0.00 | 0.9995 |
| IT_NTT | 1.95354 | 1.09 | 0.5800 | 0.24 | 0.6234 |

| Obs | FOR | SD | UCL | LCL | AKT | e | \|e\| | e^2 | \|e/yt\| | MAPE | RMSE |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 64 | 142,495 | 1,342 | 139,866 | 145,125 | 140,870 | -1,625 | 1,625 | 2,642 | 0,012 | 3,703 | 7,005 |
| 65 | 141,503 | 2,424 | 136,752 | 146,254 | 143,840 | 2,337 | 2,337 | 5,460 | 0,016 | | |
| 66 | 141,002 | 3,384 | 134,370 | 147,635 | 145,330 | 4,328 | 4,328 | 18,730 | 0,030 | | |
| 67 | 140,749 | 4,228 | 132,463 | 149,035 | 141,900 | 1,151 | 1,151 | 1,325 | 0,008 | | |
| 68 | 140,621 | 4,974 | 130,872 | 150,371 | 142,170 | 1,549 | 1,549 | 2,399 | 0,011 | | |
| 69 | 140,557 | 5,643 | 129,496 | 151,618 | 142,010 | 1,453 | 1,453 | 2,112 | 0,010 | | |
| 70 | 140,524 | 6,251 | 128,273 | 152,775 | 143,550 | 3,026 | 3,026 | 9,156 | 0,021 | | NTB |
| 71 | 140,508 | 6,808 | 127,163 | 153,852 | 146,500 | 5,992 | 5,992 | 35,908 | 0,041 | | |
| 72 | 140,499 | 7,326 | 126,141 | 154,858 | 148,320 | 7,821 | 7,821 | 61,163 | 0,053 | | |
| 73 | 140,495 | 7,810 | 125,187 | 155,803 | 152,670 | 12,175 | 12,175 | 148,227 | 0,080 | | |
| 74 | 140,493 | 8,267 | 124,291 | 156,695 | 148,060 | 7,567 | 7,567 | 57,259 | 0,051 | | |
| 75 | 140,492 | 8,699 | 123,441 | 157,542 | 152,810 | 12,318 | 12,318 | 151,734 | 0,081 | | |
| 76 | 140,491 | 9,112 | 122,633 | 158,350 | 153,160 | 12,669 | 12,669 | 160,493 | 0,083 | | |
| 77 | 140,491 | 9,506 | 121,859 | 159,123 | 149,410 | 8,919 | 8,919 | 79,546 | 0,060 | | |

| Obs | FOR | SD | UCL | LCL | AKT | e | \|e\| | e^2 | \|e/yt\| | MAPE | RMSE |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 64 | 114,544 | 0,578 | 113,410 | 115,677 | 116,050 | 1,506 | 1,506 | 2,268 | 0,013 | 3,413 | 4,392 |
| 65 | 114,157 | 0,900 | 112,393 | 115,920 | 116,230 | 2,073 | 2,073 | 4,298 | 0,018 | | |
| 66 | 113,962 | 1,187 | 111,635 | 116,288 | 116,850 | 2,888 | 2,888 | 8,343 | 0,025 | | |
| 67 | 113,863 | 1,444 | 111,033 | 116,692 | 117,310 | 3,447 | 3,447 | 11,883 | 0,029 | | |
| 68 | 113,813 | 1,674 | 110,532 | 117,094 | 117,320 | 3,507 | 3,507 | 12,299 | 0,030 | | |
| 69 | 113,788 | 1,882 | 110,100 | 117,476 | 118,380 | 4,592 | 4,592 | 21,088 | 0,039 | | |
| 70 | 113,775 | 2,072 | 109,715 | 117,836 | 119,040 | 5,265 | 5,265 | 27,719 | 0,044 | | NTT |
| 71 | 113,769 | 2,247 | 109,365 | 118,173 | 118,750 | 4,981 | 4,981 | 24,814 | 0,042 | | |
| 72 | 113,765 | 2,410 | 109,042 | 118,489 | 118,810 | 5,045 | 5,045 | 25,448 | 0,042 | | |
| 73 | 113,764 | 2,563 | 108,740 | 118,787 | 119,600 | 5,836 | 5,836 | 34,061 | 0,049 | | |
| 74 | 113,763 | 2,708 | 108,456 | 119,070 | 119,700 | 5,937 | 5,937 | 35,248 | 0,050 | | |
| 75 | 113,763 | 2,845 | 108,187 | 119,338 | 119,440 | 5,677 | 5,677 | 32,233 | 0,048 | | |
| 76 | 113,762 | 2,976 | 107,930 | 119,595 | 118,560 | 4,798 | 4,798 | 23,018 | 0,040 | | |
| 77 | 113,762 | 3,101 | 107,684 | 119,841 | 118,920 | 5,158 | 5,158 | 26,602 | 0,043 | | |