BAREKENG: Journal of Mathematics and Its Applications
March 2022 Volume xx Issue xx Page xxx–xxx
P-ISSN: 1978-7227 E-ISSN: 2615-3017
https://doi.org/10.30598/barekengxxxxxxxxxxxxx

PERAMALAN DERET WAKTU HARGA SAHAM ALIBABA (BABA) MENGGUNAKAN PENDEKATAN LSTM DAN XGBOOST

Amadea Inchrisa[1*], Anita Diah Anggraini[2], M. Aldevaran Jaylani Antares[3], Meidiantha Nataniel Bangun[4], Nabila Alyani Hanifah[5], Revana Moza Hendriani[6], Rifqi Adi Mahmada[7], Rizal Afandi[8]

[1,2,3,4,5,6,7,8]*Program Studi Statistika, Departemen Statistika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember*
Kampus ITS Sukolilo, Surabaya, 60111, Indonesia

*Corresponding author's e-mail: * **5003221166@student.its.ac.id***

Article History:

Received: date, month year
Revised: date, month year
Accepted: date, month year

Keywords:

Alibaba, LSTM, Peramalan Saham, Time Series, XGBoost

ABSTRACT

Pasar saham merupakan lingkungan investasi yang sangat dinamis dan berisiko tinggi, dengan pergerakan harga yang dipengaruhi berbagai faktor kompleks. Oleh karena itu, prediksi harga saham menjadi kebutuhan strategis bagi investor. Penelitian ini bertujuan untuk membandingkan kinerja dua metode peramalan deret waktu, yaitu Long Short-Term Memory (LSTM) dan Extreme Gradient Boosting (XGBoost), dalam memprediksi harga saham harian Alibaba (BABA) periode 2015–2024. Data diambil dari Yahoo Finance, dengan fokus pada harga penutupan (close price). Tahapan penelitian meliputi uji linearitas, normalisasi data untuk model LSTM, feature engineering untuk XGBoost, pembagian data latih dan uji secara kronologis, serta tuning hyperparameter menggunakan Optuna. Hasil uji linearitas menunjukkan adanya pola non-linear dalam data, sehingga penggunaan model non-linear menjadi relevan. Hasil evaluasi performa menunjukkan bahwa model XGBoost memberikan hasil prediksi lebih akurat dibanding LSTM, dengan nilai MAE, RMSE, dan R-Squared yang lebih baik, baik pada data latih maupun data uji. Model XGBoost juga menunjukkan kemampuan generalisasi yang unggul dan konsisten terhadap data baru. Temuan ini merekomendasikan model XGBoost sebagai alat bantu prediksi harga saham Alibaba, yang dapat digunakan investor untuk pengambilan keputusan investasi berbasis data.

This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution-ShareAlike 4.0 International License.

How to cite this article:

Amadea Inchrisa, Anita Diah Anggraini, M. Aldevaran Jaylani Antares, Meidiantha Nataniel Bangun, Nabila Alyani Hanifah, Revana Moza Hendriani, Rifqi Adi Mahmada, Rizal Afandi., "Peramalan Deret Waktu Harga Saham Alibaba (Baba) Menggunakan Pendekatan LSTM daan XGBoost," *BAREKENG: J. Math. & App.*, vol. xx, iss. xx, pp. xxx-xxx, Month, Year.

Copyright © 2022 Author(s)
Journal homepage: *https://ojs3.unpatti.ac.id/index.php/barekeng/*
Journal e-mail: *barekeng.math@yahoo.com; barekeng.journal@mail.unpatti.ac.id*

Research Article · Open Access

1. PENDAHULUAN

1.1 Latar Belakang

Industri pasar saham merupakan salah satu arena investasi yang sangat dinamis, kompetitif, dan penuh risiko, yang ditandai oleh tingginya volatilitas harga serta ketidakpastian kondisi pasar yang kompleks. Fluktuasi harga saham yang terjadi secara cepat, acak, dan dipengaruhi oleh berbagai faktor makro dan mikro ekonomi, menjadikan pasar saham sebagai lingkungan yang sangat menantang bagi para investor dan pelaku keuangan. Perubahan harga yang drastis dalam waktu singkat tidak jarang menimbulkan risiko kerugian yang besar apabila tidak disertai dengan strategi investasi yang tepat. Dalam konteks ini, kesalahan dalam pengambilan keputusan investasi, seperti waktu pembelian atau penjualan saham yang tidak tepat, dapat berdampak signifikan terhadap portofolio investasi. Oleh karena itu, kemampuan untuk memprediksi arah dan besarnya perubahan harga saham menjadi kebutuhan yang sangat vital dan strategis dalam dunia pasar modal [1]. Prediksi yang akurat dapat membantu investor untuk mengoptimalkan pengambilan keputusan, meminimalisasi risiko kerugian, serta memaksimalkan potensi keuntungan yang tersedia di pasar. Seiring berkembangnya teknologi informasi dan data yang semakin besar volumenya, pendekatan berbasis machine learning dan deep learning telah menunjukkan potensi besar dalam mengatasi tantangan prediksi pasar saham secara lebih efisien dan akurat [2].

Pasar saham sangat dipengaruhi oleh berbagai faktor yang terekam dalam data historis seperti harga pembukaan (open), harga tertinggi (high), harga terendah (low), harga penutupan (close), dan volume transaksi. Data ini mencerminkan dinamika pasar dari waktu ke waktu dan sering digunakan dalam berbagai studi untuk mengembangkan sistem prediksi yang lebih presisi [3]. Dalam penelitian ini, digunakan data harga saham harian dari perusahaan Alibaba Group Holding Ltd. (BABA). Data tersebut memberikan informasi teknikal yang komprehensif yang dapat dimanfaatkan dalam membangun model prediktif berbasis time-series.

Untuk menghadapi kompleksitas dalam pola pergerakan harga saham, dua algoritma yang digunakan dalam penelitian ini adalah XGBoost dan Long Short-Term Memory (LSTM). XGBoost merupakan algoritma gradient boosting yang efisien dan dirancang untuk memberikan akurasi tinggi serta mengatasi overfitting melalui regularisasi [4]. Algoritma ini telah terbukti handal dalam tugas klasifikasi dan regresi pada berbagai domain, termasuk prediksi pasar saham [1].

Sementara itu, LSTM merupakan arsitektur deep learning yang dirancang khusus untuk menangani data sekuensial dan memiliki kemampuan dalam mengingat informasi jangka panjang. Keunggulan LSTM terletak pada struktur sel memori dan gerbang yang mampu mempertahankan konteks historis dalam prediksi, menjadikannya sangat cocok untuk menganalisis tren dalam data harga saham [5]. Kombinasi kekuatan LSTM dalam menangani data temporal dan efisiensi XGBoost dalam pemodelan non-linear menjadikan kedua metode ini saling melengkapi untuk memberikan prediksi yang lebih akurat.

Berdasarkan latar belakang tersebut, penelitian ini bertujuan untuk membandingkan efektivitas metode XGBoost dan LSTM dalam memprediksi arah pergerakan harga saham berdasarkan data historis perusahaan Alibaba. Diharapkan bahwa hasil dari penelitian ini tidak hanya memberikan wawasan terhadap performa kedua algoritma dalam konteks prediksi pasar saham, tetapi juga memberikan kontribusi ilmiah dalam pengembangan sistem prediksi yang dapat digunakan sebagai referensi oleh investor maupun pengambil kebijakan dalam merancang strategi investasi berbasis data yang lebih informatif dan responsif terhadap dinamika pasar saham.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana karakteristik dan pola data historis dari harga penutupan saham Alibaba (BABA) pada periode 2015-2024 berdasarkan data hairan?
2. Seberapa akurat model XGBoost dan *Long Short-Term Memory* (LSTM) dalam melakukan prediksi harga penutupan saham Alibaba?
3. Bagaimana perbandingan model XGBoost dan LSTM, manakah yang menunjukkan tingkat akurasi prediksi terbaik berdasarkan nilai metrik evaluasi kuantitatif, seperti *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan koefisien determinasi (*R-squared*)?
4. Bagaimana model peramalan tersebut dapat dimanfaatkan sebagai alat bantu dalam pengambilan keputusan investasi pada saham Alibaba?

1.3 Tujuan Penelitian

Sejalan dengan rumusan masalah yang telah ditetapkan, tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis dan memvisualisasikan data historis harga saham harian Alibaba (BABA) untuk mengidentifikasi pola pergerakan, tren, dan karakteristik datanya.
2. Mengimplementasikan dan melatih model peramalan harga saham menggunakan algoritma XGBoost dan *Long Short-Term Memory* (LSTM) pada data saham Alibaba (BABA).
3. Membandingkan kinerja dan akurasi dari kedua model (XGBoost dan LSTM) dengan menggunakan metrik evaluasi kuantitatif, seperti *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan koefisien determinasi (*R-squared*).
4. Menyajikan interpretasi dari hasil model peramalan terbaik sebagai landasan untuk pengambilan keputusan investasi berbasis data pada saham Alibaba (BABA).

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat baik secara akademik maupun praktis. Secara akademis, penelitian ini berkontribusi pada bidang ilmu data dan machine learning, khususnya dalam konteks peramalan deret waktu, dengan menyajikan perbandingan kinerja mendalam antara model Long Short-Term Memory (LSTM) dan XGBoost. Analisis ini memperkaya literatur serta pemahaman tentang penerapan kedua metode tersebut pada data harga saham Alibaba (BABA) yang dinamis dan non-linear, sekaligus dapat menjadi rujukan untuk riset di masa depan. Di sisi praktis, hasil penelitian ini dapat dimanfaatkan secara langsung oleh investor dan analis pasar, karena memberikan evaluasi yang jelas mengenai kelebihan serta kekurangan dari masing-masing model dalam konteks data spesifik. Dengan pemahaman tersebut, para pelaku pasar dapat memilih metode peramalan yang paling sesuai dengan kebutuhan analisis mereka, yang pada akhirnya akan mendukung proses pengambilan keputusan investasi yang lebih akurat dan berbasis data.

1.5 Batasan Masalah

Untuk menjaga fokus dan ruang lingkupnya, penelitian ini memiliki beberapa batasan yang perlu diperhatikan. Objek penelitian ini secara spesifik hanya mengkaji pergerakan harga saham Alibaba (BABA) dalam periode 2015-2024, sehingga hasilnya mungkin tidak dapat langsung diterapkan pada saham dengan karakteristik pasar yang berbeda. Fokus pemodelan terbatas pada dua pendekatan, yaitu XGBoost dan *Long Short-Term Memory (*LSTM). Hal ini berarti penelitian tidak menyediakan perbandingan komprehensif dengan metode deret waktu lainnya, seperti model statistik tradisional (ARIMA) atau arsitektur *deep learning* yang lebih baru, yang mungkin dapat memberikan hasil berbeda. Selanjutnya, evaluasi performa hanya diukur berdasarkan akurasi nilai prediksi menggunakan metrik MAE, RMSE, dan R-Squared, dan tidak mengukur aspek lain seperti ketepatan prediksi arah. Penelitian ini juga bersifat univariat, yang berarti analisisnya hanya menggunakan data harga penutupan (*closing price*) dan mengabaikan pengaruh faktor eksternal seperti sentimen berita atau data fundamental yang dapat memengaruhi pergerakan harga saham. Terakhir, seluruh data historis yang digunakan dalam penelitian ini bersumber dari pustaka *Python yfinance*. Oleh karena itu, validitas, kelengkapan, dan akurasi dari seluruh temuan penelitian ini sangat bergantung pada keandalan data yang disediakan oleh platform tersebut.

2. TINJAUAN PUSTAKA

2.1 Saham Alibaba (BABA)

Alibaba Group adalah salah satu raksasa teknologi asal Tiongkok yang didirikan oleh Jack Ma pada tahun 1999. Perusahaan ini memiliki portofolio bisnis yang sangat luas, mulai dari e-commerce (Taobao, Tmall), keuangan digital (Alipay, Ant Group), logistik (Cainiao), hingga layanan cloud computing (Aliyun). Seiring waktu, Alibaba mengalami pertumbuhan pesat dan mencatatkan sahamnya di Bursa Saham New York pada tahun 2014, serta di Bursa Saham Hong Kong pada 2019. Dalam beberapa tahun terakhir, Alibaba menjalani transformasi besar melalui struktur bisnis baru yang dikenal sebagai model “1 + 6 + N”, di mana “1” adalah perusahaan induk inti, “6” mencakup enam kelompok usaha utama, dan “N” adalah anak-anak perusahaan di berbagai sektor strategis seperti keuangan, kesehatan, dan pendidikan [6].

Alibaba menjadi perusahaan publik setelah mencatatkan sahamnya di Bursa Saham Hong Kong pada tahun 2007 dengan nilai IPO sebesar 1,5 miliar USD. Setelah IPO tersebut, harga saham Alibaba menunjukkan kinerja yang sangat baik. Pendekatan bisnis jangka panjang yang diterapkan oleh Jack Ma

menjadikan Alibaba lebih berfokus pada keberlanjutan jangka panjang daripada sekadar mengejar keuntungan jangka pendek. Ke depannya, Alibaba merencanakan untuk kembali melakukan IPO dengan estimasi valuasi antara 60 hingga 100 miliar USD. Jika terealisasi, IPO ini berpotensi menjadi yang terbesar di sektor teknologi sejak Facebook. Dana yang diperoleh dari IPO tersebut direncanakan akan digunakan untuk mengembangkan layanan mobile dan logistik (Cainiao), mengembangkan sistem operasi sendiri (AMOS), serta akuisisi strategis di pasar global.

2.2 Peramalan

Teori peramalan didasarkan pada asumsi bahwa pengetahuan saat ini dan masa lalu dapat digunakan untuk membuat prediksi tentang masa depan. Secara khusus untuk *time series*, terdapat keyakinan bahwa pola dalam nilai historis dapat diidentifikasi dan diterapkan dengan baik dalam proses memprediksi nilai-nilai di masa depan. Teori peramalan dikembangkan dalam bentuk metode dan model peramalan. Metode peramalan didefinisikan sebagai sebagai suatu urutan langkah yang telah ditentukan sebelumnya untuk meramalkan hasil pada periode mendatang. Banyak metode peramalan yang memiliki model stokastik yang menghasilkan peramalan titik yang sama. Model stokastik dapat membangkitkan data yang digunakan untuk menghasilkan interval prediksi dan distribusi prediksi secara keseluruhan. Peramalan dapat dihasilkan dari suatu prose yang menggabungkan metode atau model peramalan baru dan/atau yang sudah ada. Penggabungan peramalan dan berbagai metode dapat menjadikan metode permalan menjadi lebih efektif [7].

Terdapat 2 jenis peramalan apabila dibagi berdasarkan sifat variable, yaitu peramalan univariat dan peramalan multivariat. Dalam peramalan univariat, peramalan dikembangkan untuk satu deret waktu dengan menggunakan informasi dari nilai historis deret waktu itu sendiri. Sementara dalam peramalan univariat, variable deret waktu lain turut dilibatkan dalam menghasilkan peramalan. Baik dalam peramalan univariat maupun univariat dpat mempertimbangkan adanya intervensi. Hubungan antar variable dan jenis input lainnya dapat bersifat linear atau melibatkan struktur non-linear. Apabila bentuk fungsi eksplisit tidak tersedia, maka metode seperti *artificial neuron networks* dapat digunakan [7].

Sebelum menerapkan metode peramalan, data mungkin memerlukan proses pre-pemrosesan (*pre-processing*). Ada langkah-langkah dasar yang perlu dilakukan, seperti memeriksa keakuratan data dan menatasi nilai yang hilang. Beberapa hal perlu dilakukan sebelum proses peramalan, namun Sebagian ada yang menjadi bagian dari metode peramalan itu sendiri. Setelah melakukan peramalan, sangat penting untuk mengavaluasi efektivitas metode yang digunakan. Aplikasi akhir dari hasil peramalan memberikan panduan tentang bagaimana mengukur tingkat akurasinya. Evaluasi biasanya berfokus pada perbedaan antara nilai aktual dengan peramalan titik tersebut.

2.3 Time Series

Analisis *time series* berkaitan dengan metode statistik untuk menganalisis dan memodelkan urutan data yang teratur. Pemodelan ini menghasilkan model proses stokastik untuk sistem yang menghasilkan model proses stokastik untuk sistem yang menghasilkan data tersebut. Urutan pengamatanumumnya dilakukan dalam interval waktu yang sama. Model *time series* dibagi menjadi 2, yaitu model linear dan non-linear. Pemilahan antara model linear dan non-linear dimaksudkan untuk memperjelaspendekatan matematis yang sangat berbeda yang diperlukan dalam masing-masing kasus. Metode *time series* juga sering dianggap sebagai perluasan dari regresi linear. Di mana, observasi masa lalu variabel dependen digunakan sebagai variabel penjelas. Selain itu, pada *time series* terdapat komponen-komponen penting yang menjadi penyusunnya. Komponen tersebut adalah *trend*, *seasonal*, *cyclic*, dan *residual*. *Trend* merupakan pola jangka panjang dari data, bisa merupakan tren naik atau turun. *Seasonal* merupakan pola berulang yang terjadi dalam periode waktu yang tetap. *Cyclic* merupakan fluktuasi jangka panjang yang tidak teratur, sedangkan *residual* merupakan komponen acak atau gangguan yang tdiak bisa diprediksi [8].

Model *time series* dibagi menjadi dua, yaitu model adisi dan model multiplikatif. Model adisi digunakan apabila komponen tidak saling memengaruhi secara proporsional. Bentuk dari model adisi adalah seperti berikut.

$$Yt = Tt + St + Ct + It \tag{1}$$

Sedangkan model multiplikatif digunakan jika fluktuasi musiman bergantung pada besar kecilnya nilai deret. Bentuk dari model multiplikatif adalah sebagai berikut.

$$Yt = Tt \times St \times Ct \times It \tag{2}$$

Kemudian untuk menganalisis *time series*, dapat digunakan berbagai macam metode. Beberapa metode yang banyak digunakan adalah metode *exponential smoothing*, model ARIMA, LSTM, serta XGBoost.

2.4 Uji Linearitas Data *Time Series*

Uji linearitas merupakan langkah penting dalam analisis data *time series* untuk memastikan bahwa hubungan antar variabel dapat secara akurat dijelaskan menggunakan pendekatan linear. Jika hubungan data bersifat non-linear, penggunaan model linear tradisional seperti ARIMA dapat menghasilkan estimasi yang bias atau tidak efisien. Oleh karena itu, pengujian ini esensial untuk menghindari kesalahan spesifikasi model dan pada akhirnya meningkatkan akurasi peramalan [9]. Metode statistik yang umum digunakan untuk tujuan ini adalah Uji *Neural Network Terasvirta*, di mana metode ini memiliki pendekatan untuk mendeteksi keberadaan non-linearitas.

Dalam studi kasus peramalan harga saham Alibaba (BABA), Uji *Neural Network Terasvirta* dipilih sebagai salah satu metode untuk mengidentifikasi sifat linearitas data. Metode ini, yang merupakan pengembangan dari model *Smooth Transition Autoregressive* (STAR), yang secara spesifik dirancang untuk mendeteksi pola non-linear pada data deret waktu dengan memanfaatkan pendekatan jaringan saraf tiruan [10]. Mekanisme uji ini bekerja dengan membandingkan model regresi linear konvensional dengan model alternatif non-linear yang diwakili oleh jaringan saraf sederhana (*single-layer neural network*). Apabila komponen non-linear dari jaringan saraf tersebut terbukti signifikan secara statistik, maka ini menjadi bukti kuat bahwa hubungan dalam data bersifat non-linear. Mengingat harga saham Alibaba (BABA) memiliki volatilitas tinggi dan sering mengalami pergeseran struktural, uji ini menjadi sangat relevan. Metode ini dianggap efektif untuk mendeteksi "perubahan rezim" atau pola-pola non-linear tersembunyi dalam pergerakan harga aset tersebut [11].

Hipotesis:
H_0 : Data terindikasi linear apabila diuji menggunakan estimasi *Neural Network*
H_1 : Data terindikasi non-linear apabila diuji menggunakan estimasi *Neural Network*

Statistik Uji:

$$LR = T \cdot \left(R_{NN}^2 - R_{linear}^2\right) \sim X_k^2 \tag{3}$$

Keterangan:
LR : nilai statistik *likelihood ratio*
T : jumlah observasi
R_{NN}^2 : koefisien determinasi dari model *neural network*
R_{linear}^2 : koefisien determinasi dari model linear
k : jumlah parameter tambahan pada model neural network dibanding model linear
Distribusinya mengikuti distribusi Chi-kuadrat X^2 dengan k derajat bebas

Peran Uji *Neural Network Terasvirta* sebagai alat diagnostik esensial dalam meletakkan dasar untuk pemilihan model peramalan yang paling cocok, terutama untuk data yang dinamis dan kompleks seperti harga saham Alibaba [9].

2.5 Machine Learning

Machine learning adalah bidang yang berfokus pada spekpembelajaran dan kecerdasan buatan dengan mengembangkan algoritma yang paling tepat untuk merepresentasikan suatu kumpulan data. Berbeda dengan pemrograman klasik di mana algoritma secara eksplisit dapat dikodekan menggunakan fitur-fitur yang telah diketahui, machine learning menggunakan subsest data untuk menghasilkan algoritma yang mungkin menggunakan kombinasi fitur dan bobot yang baru atau berbeda dari yang bisa diperoleh berdasarkan prinsip dasar [12].

Dalam machine learning, terdapat empat metode yang umum digunakan, yaitu Supervised Learning, Unsupervised Learning, Semisupervised Learning, dan Reinforcement Learning. Supervised Learning digunakan untuk memprediksi data numerik menggunakan regresi serta memprediksi data kategorik menggunakan klasifikasi. Metode ini belajar menggunakan pola fitur-target dalam data pelatihan (train) untuk memetakan fitur ke target, sehingga algoritma dapat membuat prediksi data baru di masa depan. Kemudian kinerja algoritma dievaluasi menggunakan test set yaitu data yang belum pernah dilihat oleh algoritma sebelumnya. Berkebalikan dnegan Supervised learning, metode Unsupervised Learning tidak mempelajari pola atau tidak diberi informasi target. Metode ini membiarkan algoritma untu menemukan polanya sendiri.

Unsupervised Learning digunakan saat tidak memiliki target untuk diprediksi dan tujuan dari analisis adalah untuk menemukan struktur tersembunyi dalam data. Tugas dari metode ini adalah untuk melakukan *clustering*, asosiasi, serta mendeteksi anomali pada data.

Metode selanjutnya adalah Semisupervised Learning yang dianggap sebagai jalan tengah dari Supervised dan Unsupervised Learning. Metode ini sangat berguna untuk data yang memiliki campuran data berlabel dan tidak berlabel. Metode ini dilatih dengan diberikan sebagian data dengan label kemudian terbentuk model awal. Model awal ini kemudian digunakan untuk menganalisis data lain yang tidak memiliki label. Metode ini memiliki beberapa manfaat yaitu dapat menghemat waktu dan biaya, memanfaatkan data tak berlabel secara efektif, serta meningkatkan performa model. Terakhir ada Reinforcement Learning, yaitu teknik untuk melatih algoritma dalm suatu tugas tertentu di mana tidak ada satu jawaban yang benar, namun tetap ada tujuan akhir yang ingin dicapai. Metode ini sering dianggap sebagai pendekatan yang paling mirirp dengan cara manusia belajar, karena lagoritma mengalami *trial* dan *error*. Dalam *reinforcement learning*, algoritma dibiarkan untuk bekerja sendiri hingga dapat menyelesaikan analisis hingga akhir [12].

2.6 Deep Learning

Deep Learning adalah salah satu cabang machine learning yang menggunakan Jaringan Saraf Tiruan (JST) berlapis untuk meniru cara kerja otak manusia dalam memproses informasi. Pendekatan ini dirancang untuk secara otomatis mengekstraksi pola dan fitur kompleks dari kumpulan data berskala besar [13]. Metode ini terbukti sangat efektif untuk menangani data deret waktu yang rumit dan non-linear, seperti pergerakan harga saham Alibaba. Dalam konteks ini, model *deep learning* seperti *Long Short-Term Memory* (LSTM) menjadi sangat populer. Keunggulan utama LSTM adalah kemampuannya untuk mengatasi masalah vanishing gradient yang sering membatasi kinerja model *Recurrent Neural Networks* (RNN) biasa. Dengan menggunakan unit memori khusus, LSTM dapat mengingat informasi penting dari periode waktu yang jauh di masa lalu, memungkinkannya untuk mempelajari dan memodelkan pola jangka panjang secara lebih efisien.

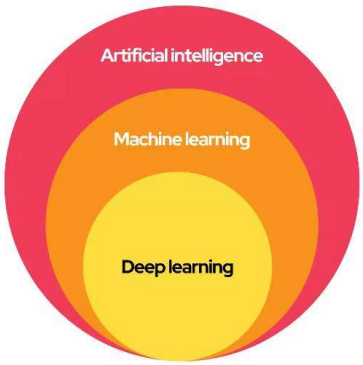

Gambar 2.1. Struktur *Artificial Intelligence*

Model seperti LSTM dan variasinya secara signifikan lebih baik dalam meramalkan harga *cryptocurrency* dibandingkan model statistik tradisional seperti ARIMA. Keunggulan utama LSTM terletak pada kemampuannya untuk mengenali dan mempelajari ketergantungan data jangka panjang, sebuah karakteristik yang sangat relevan untuk data yang sangat volatil dan tidak stasioner seperti harga aset digital. Selain itu, model *deep learning* juga terbukti lebih toleran terhadap *noise* (gangguan) dan *outlier* (data ekstrem) yang umum terjadi di pasar keuangan [13]. Beberapa studi yang lebih baru semakin memperkuat temuan ini. Akurasi prediksi dapat ditingkatkan secara substansial ketika model *deep learning* digabungkan dengan teknik lain untuk menciptakan model hibrida [14][15].Pendekatan *deep learning* tidak hanya kompeten untuk tugas peramalan, tetapi juga sangat adaptif terhadap kompleksitas pasar yang terus berubah.

2.7 *Neural Network* dalam Time series

Neural Network (NN) atau jaringan syaraf tiruan (JST) merupakan sistem yang mensimulasikan proses pembelajaran yang memiliki karakteristik mirip dengan jaringan syaraf manusia, dimana dalam memproses informasi, terdapat banyak unit pemroses informasi (neuron) yang cukup kompleks dan bekerja secara paralel. NN dikembangkan untuk menyelesaikan permasalahan prediksi, klasifikasi, maupun pengenalan pola, Jaringan ini terdiri atas lapisan-lapisan neuron yang saling terhubung dan bekerja secara paralel, dengan proses pembelajaran yang dilakukan melalui penyesuaian bobot antar neuron berdasarkan pengalaman data pelatihan yang diberikan [16]. Arsitektur NN umumnya mencakup lapisan input, lapisan

tersembunyi (*hidden layer*), dan lapisan output, dnegan fungsi aktivasi yang digunakan untuk mengubah input menjasi sinyal output dalam setiap neuron [17].

NN saat ini telah berkembang sebagai metode yang efektif dalam menyelesaikan masalah peramalan deret waktu (*time series forecasting)*, terutama ketika data bersifat nonlinear atau memiliki *noise* yang tinggi. Berbeda dengan model statistik tradisional seperti ARIMA yang memiliki syarat asumsi tertentu pada data, seperti stasioneritas dan normalitas, *Neural Network* mampu melakukan prediksi tanpa memerlukan asumsi tersebut [18]. Dengan demikian menjadikan *Neural Network* cocok diterapkan pada data dengan pola kompleks dalam banyak kasus aplikasi nyata, seperti prediksi permintaan, inflasi, harga saham, hingga kekuatan gempa bumi. Kelebihan lain dari Neural Network dalam peramalan deret waktu antara lain adalah kemampuannya dalam melakukan generalisasi, toleransi terhadap kesalahan input, serta fleksibilitas arsitektur jaringan yang dapat disesuaikan untuk meningkatkan performa prediksi.

2.8 *Short Term Memory* (LSTM)

Long Short-Term Memory (LSTM) adalah jenis arsitektur Recurrent Neural Network (RNN) yang dirancang khusus untuk memodelkan dan belajar dari dependensi jangka panjang dalam data sekuensial seperti deret waktu [19]. Berbeda dengan RNN tradisional yang cenderung mengalami masalah vanishing gradient atau exploding gradient saat memproses urutan panjang, LSTM memperkenalkan unit memori yang disebut "sel" (cell) dan mekanisme "gerbang" (gates) yang mengatur aliran informasi ke dalam dan ke luar dari sel [20]. Setiap sel LSTM pada dasarnya memiliki tiga gerbang utama yang mengontrol aliran informasi:

- ***Forget Gate*** (ft): Menentukan informasi mana dari status sel sebelumnya (Ct−1) yang harus dilupakan.

$$f_t = \sigma\left(W_f.[h_{t-1}, x_t] + b_f\right) \tag{4}$$

- ***Input Gate (it):*** Menentukan informasi baru mana yang akan disimpan dalam status sel saat ini

$$\tilde{C}_t = \tanh(W_c.[h_{t-1}, x_t] + b_c) \tag{5}$$

$$i_i = \sigma(W_i.[h_{t-1}, x_t] + b_i) \tag{6}$$

Status sel yang diperbarui adalah: $C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$.

- ***Output Gate (ot):*** Memutuskan bagian mana dari status sel yang akan dikeluarkan sebagai hidden state (ht) untuk langkah waktu berikutnya.

$$o_t = \sigma(W_o.[h_{t-1}, x_t] + b_o) \tag{7}$$

$$h_t = o_t.\tanh\,(C_t) \tag{8}$$

Di mana xt adalah input saat ini, ht−1 adalah *hidden state* sebelumnya, Ct−1 adalah status sel sebelumnya, σ adalah fungsi aktivasi sigmoid, tanh adalah fungsi aktivasi *hyperbolic tangent*, dan W serta b adalah bobot dan bias yang dipelajari. Variabel c dan h merepresentasikan status saat ini dan *hidden state* dari sel LSTM, sementara input direpresentasikan oleh variabel x. Gerbang sigmoid di dalam blok merupakan *forget gate*, *input gate*, dan *output gate* secara berurutan. Status saat ini diperbarui sehubungan dengan input, sesuai dengan jumlah status saat ini dan kombinasi input serta *hidden state* dari blok.

Dengan mekanisme ini, LSTM sangat efektif dalam menangkap pola temporal yang kompleks dan dependensi jangka panjang, menjadikannya pilihan yang kuat untuk peramalan deret waktu yang rumit, seperti data keuangan atau cuaca yang sangat volatil [20]. Sebagian besar penelitian terbaru (sejak 2019) yang membandingkan ARIMA dengan teknik *deep learning* memilih jaringan LSTM atau variannya, karena kemampuan memorinya dan untuk mengatasi masalah *vanishing gradient* [21].

2.9 *Extreme Gradient Boosting* (XGBoost)

Extreme Gradient Boosting (XGBoost) adalah algoritma ensemble learning yang sangat efisien dan populer, berbasis pada kerangka kerja gradient boosting. Algoritma ini membangun model prediktif secara sekuensial dengan menggabungkan banyak pohon keputusan (decision trees), di mana setiap pohon baru ditambahkan untuk mengoreksi kesalahan yang dibuat oleh kombinasi pohon sebelumnya [22].

Kekuatan utama XGBoost terletak pada kombinasinya antara kinerja tinggi dan efisiensi komputasi. Algoritma ini dirancang untuk dapat diskalakan pada dataset besar, memanfaatkan komputasi paralel untuk mempercepat pelatihan [23]. Selain itu, XGBoost mengintegrasikan berbagai teknik regularisasi (seperti L1 dan L2) untuk mencegah overfitting dan meningkatkan generalisasi model [22].

Secara matematis, XGBoost bekerja dengan meminimalkan fungsi objektif (objective function) yang telah didefinisikan. Fungsi objektif ini terdiri dari dua komponen utama: fungsi kerugian (loss function) dan term regularisasi. Fungsi objektif untuk model prediksi phi pada iterasi *t* dapat dinyatakan sebagai berikut.

$$\mathcal{L}^{(t)}(\phi) = \sum_{i=1}^{n} l\left(y_i, \widehat{y_i^{(t-1)}} + f_t(x_i)\right) + \sum_{k=1}^{t} \Omega(f_k) \tag{9}$$

dimana:

- $\sum_{i=1}^{n} l\left(y_i, \widehat{y_i^{(t-1)}} + f_t(x_i)\right)$ adalah fungsi kerugian (*loss function*), yang mengukur seberapa baik model memprediksi data. y_i adalah nilai target aktual, $y_i^{(t-1)}$ adalah prediksi dari model pada iterasi sebelumnya, dan $f_t(x_i)$ adalah fungsi pohon baru yang ditambahkan pada iterasi *t*.
- $\sum_{k=1}^{t} \Omega(f_k)$ adalah term regularisasi (*regularization term*), yang mengontrol kompleksitas model dan mencegah *overfitting*. Fungsi $\Omega(f_k)$ biasanya mencakup penalti untuk jumlah daun pada pohon (*T*) dan L2-norm dari skor daun (*w*):

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 \tag{10}$$

dimana γ dan λ adalah koefisien regularisasi.

Dengan mengoptimalkan fungsi objektif gabungan ini secara iteratif menggunakan *gradient boosting*, XGBoost mampu menghasilkan model yang akurat dan kuat [24]. Karakteristik ini menjadikannya pilihan utama dalam berbagai tugas *machine learning* seperti klasifikasi, regresi, dan masalah peringkat, yang diaplikasikan di berbagai bidang [25].

2.10 Normalisasi Data

Normalisasi data merupakan tahap awal yang penting dalam pra-pemrosesan data sebelum digunakan dalam pelatihan NN. Tujuan dari normalisasi adalah untuk menyetarakan skala nilai dari setiap fitur agar berada dalam rentang tertentu, sehingga mencegaj dominasi satu fitur terhadap lainnya selama proses pelatihan. Salah satu teknik yang umum digunakan adalah *min-max normalization,* yaitu mengubah nilai setiap data ke dalam rentang 0 hingga 1 menggunakan rumus berikut:

$$x' = \left(\frac{x - x_{min}}{x_{max} - x_{min}}\right) \tag{11}$$

di mana x' adalah nilai hasil normalisasi, x adalah nilai asli, serta $x_{\min}$ dan $x_{\max}$ masing-masing adalah nilai minimum dan maksimum dari atribut tersebut [26].

Penerapan normalisasi terbukti membantu meningkatkan akurasi prediksi dan stabilitas jaringan selama pelatihan, khususnya pada data deret waktu. Tanpa normalisasi, nilai input yang berada di luar rentang optimal dapat menyebabkan propagasi gradien yang ekstrem, menghambat konvergensi, dan memperlambat proses pembelajaran [27]. Ketika fungsi aktivasi seperti sigmoid digunakan, input yang terlalu besar dapat membuat neuron memasuki kondisi jenuh, sehingga gradien yang dihasilkan menjadi sangat kecil dan pembaruan bobot tidak efektif. Konsistensi skala input menjadi penting agar jaringan dapat beroperasi dalam rentang aktivasi yang optimal dan mendukung efisiensi pelatihan secara keseluruhan [28]. Dengan demikian, normalisasi data berperan signifikan dalam menunjang kinerja dan keandalan model jaringan syaraf tiruan.

2.11 *Tuning Hyper Parameter* (Optuna)

Dalam proses pembelajaran mesin (ma*chine learning)*, pengaturan *hyperparameter* merupakan tahap penting untuk mendapatkan performa model yang optimal. *Hyperparameter* adalah parameter eksternal yang ditentukan sebelum proses pelatihan dimulai dan tidak diubah selama pelatihan berlangsung, seperti jumlah neuron dalam lapisan tersembunyi (*hidden units*), tingkat pembelajaran (*learning rate*), jumlah epoch, *batch size*, serta tingkat *dropout*. Pemilihan *hyperparameter* sangat krusial karena dapat berdampak langsung pada performa akhir model. Pemilihan nilai yang terlalu rendah atau terlalu tinggi dapat menyebabkan model mengalami *underfitting* atau *overfitting*. Oleh karena itu, proses yang disebut *hyperparameter tuning* dibutuhkan untuk mencari kombinasi nilai terbaik melalui pendekatan sistematis seperti pencarian grid, pencarian acak, atau metode yang lebih canggih seperti optimasi berbasis Bayesian [27].

Salah satu metode yang banyak digunakan dalam *hyperparameter tuning* adalah Optuna, yaitu *open-source* berbasis Python. Optuna merupakan *framework* optimasi *hyperparameter* moderen yang dirancang

agar lebih adaptif dan efisien dalam menemukan kombinasi parameter terbaik pada model pembelajaran mesin. Keunggulan utamanya terletak pada pendekatan *define-by-run*, di mana pengguna dapat menetapkan ruang pencarian parameter secara fleksibel selama proses berjalan, bukan sejak awal seperti pada metode pencarian konvensional. Optuna juga memanfaatkan teknik optimasi berbasis Bayesian, khususnya melalui algoritma *Tree-structured Parzen Estimator (TPE)*, untuk memilih konfigurasi parameter secara cerdas dan bertahap. Selain itu, Optuna dilengkapi fitur *pruning* yang memungkinkan penghentian lebih awal terhadap percobaan yang tidak menjanjikan, sehingga dapat menghemat waktu dan sumber daya selama proses tuning [29]. Optuna juga sangat kompatibel dengan berbagai algoritma pembelajaran mesin, baik klasik seperti XGBoost, maupun model sekuensial seperti LSTM, dan telah terbukti mampu meningkatkan performa prediksi melalui pencarian nilai *hyperparameter* yang optimal.

2.12 Evaluasi Model

Evaluasi model dalam pembelajaran mesin memiliki peranan penting untuk mengukur seberapa baik performa model dalam melakukan prediksi terhadap data yang belum pernah dilihat sebelumnya. Berbagai metrik evaluasi digunakan, tergantung pada jenis permasalahan dan jenis data yang digunakan. Untuk tugas regresi, beberapa metrik yang umum digunakan antara lain *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan Koefisien Determinasi (R *Square*). Setiap metrik memberikan perspektif yang berbeda terhadap kualitas prediksi model.

2.12.1 Mean Absolute Error (MAE)

Mean Absolute Error (MAE) mengukur rata-rata besar kesalahan absolut antara nilai prediksi dan nilai aktual, tanpa memperhatikan arah kesalahan. Rumus MAE dituliskan sebagai berikut:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{12}$$

di mana y_i adalah nilai aktual ke$i$, $\hat{y}_i$ adalah nilai prediksi ke-i, dan n adalah jumlah total data. MAE memberikan ukuran kesalahan yang mudah diinterpretasikan karena berada dalam satuan yang sama dengan data asli, namun tidak memberikan penalti tambahan terhadap kesalahan yang besar [27].

2.12.2 Root Mean Square Error (RMSE)

Root Mean Square Error (RMSE) memberikan penalti yang lebih besar pada kesalahan prediksi yang tinggi karena menggunakan kuadrat dari selisih. RMSE dinyatakan dengan rumus:

$$RMSE = \sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2} \tag{13}$$

RMSE sering digunakan karena memberikan gambaran yang lebih sensitif terhadap *outlier* dibanding MAE, dan juga berada dalam satuan yang sama dengan target variabel [27].

2.12.3 Koefisien Determinasi (*R-Square*)

Koefisien determinasi atau *R-square* mengukur proporsi variasi dari data target yang berhasil dijelaskan oleh model. Nilai berkisar antara 0 hingga 1, dengan nilai mendekati 1 menunjukkan model yang sangat baik dalam menjelaskan variasi data. Persamaan *R-square* dituliskan sebagai berikut:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \overline{y}_i)^2} \tag{14}$$

di mana $\overline{y}$ adalah rata-rata dari semua nilai aktual. R^2 berguna untuk mengevaluasi kualitas keseluruhan model, tetapi bisa menyesatkan jika digunakan pada data nonlinier atau data dengan *outlier* ekstrem [27].

3. METODOLOGI PENELITIAN

3.1. Sumber Data

Penelitian ini menggunakan data historis harian dari harga saham Alibaba (BABA). Fokus utama analisis adalah pada variabel harga penutupan (*Close*), yang dijadikan dasar untuk pemodelan dan peramalan. Rentang waktu data yang dianalisis mencakup periode dari Januari 2015 hingga Desember 2024. Seluruhnya merupakan data sekunder yang diperoleh dari situs web resmi Yahoo Finance (https://finance.yahoo.com/quote/BABA/history/). Sumber ini dipilih karena sifatnya yang terbuka (*open-*

source), mudah diakses, serta memiliki rekam jejak historis yang panjang dengan tingkat akurasi yang memadai untuk analisis deret waktu.

3.2. Data dan Variabel Penelitian

Frekuensi data yang digunakan dalam penelitian ini adalah harian (*daily*). Pemilihan frekuensi ini didasarkan pada kemampuannya untuk menyajikan analisis dinamika pergerakan harga secara mendalam, baik untuk jangka pendek maupun menengah, tanpa terdistorsi oleh fluktuasi pasar yang tidak signifikan. Dataset yang digunakan mencakup beberapa komponen fundamental yang secara kolektif menggambarkan aktivitas pasar harian, yang terdiri dari:

- *Date* : Tanggal dari setiap observasi harga saham Alibaba.
- *Open* : Nilai harga pada permulaan sesi perdagangan harian.
- *High* : Titik harga maksimum yang tercapai selama satu hari perdagangan
- *Low* : Titik harga minimum yang tercatat dalam periode harian yang sama.
- *Close* : Nilai harga final di akhir sesi perdagangan harian. Variabel ini merupakan fokus utama analisis karena perannya sebagai acuan standar dalam berbagai penelitian peramalan.
- *Volume* : Total unit yang ditransaksikan dalam satu hari perdagangan.

Fokus analisis dalam penelitian ini diarahkan pada variabel harga penutupan (*close price*), meskipun tersedia beberapa variabel pasar lainnya. Keputusan ini didasarkan pada pertimbangan bahwa harga penutupan merupakan representasi nilai aset yang paling stabil dan mencerminkan konsensus pasar di akhir sesi perdagangan. Karakteristik ini menjadikannya input yang paling relevan untuk peramalan menggunakan model XGBoost dan LSTM. Adapun struktur data final yang digunakan untuk pemodelan dirinci pada Tabel 3.1.

Tabel 3.1. Struktur Data Penelitian

Tanggal	*Close Price*
t_1	z_1
t_2	z_2
⋮	⋮
t_{2516}	z_{2516}

3.3. Langkah Penelitian

Berikut merupakan langkah-langkah sistemastis yang dilakukan dalam analisis data:

1. Mengunduh data harga harian saham Alibaba (BABA) dari Yahoo Finance untuk periode Januari 2015 hingga Desember 2024.
2. Menggunakan variabel Close Price sebagai fokus analisis.
3. Menampilkan visualisasi awal harga penutupan untuk mengamati tren umum
4. Melakukan uji linearitas terhadap data menggunakan Uji *Neural Network* Terasvirta.
5. Melakukan Preprocessing data dengan menguji Normalisasi dan membagi data menjadi dua bagian yaitu data training (data pada periode Januari 2015 hingga Desember 2022) dan data testing (Data pada periode Januari 2023 hingga Desember 2024)
6. Membuat model LSTM yang dirancang untuk memprediksi harga saham harian berdasarkan 60 hari sebelumnya.
7. Melakukan peramalan 60 hari kedepan menggunakan model LSTM.
8. Melakukan feature engineering untuk menangkap pola dan tren yang mungkin tidak terlihat dari data awal.
9. Melakukan *hyperparameter tunning* menggunakan *library Optuna* untuk menentukan parameter terbaik.
10. Melakukan peramalan 60 hari kedepan menggunakan parameter terbaik pada model XGBoost.
11. Menghitung dan membandingkan performa model LSTM dan XGBoost menggunakan metrik MAE, RMSE, dan R-Squared
12. Menentukan model terbaik berdasarkan nilai kesalahan prediksi terkecil

Pengambilan dan penyusunan data harga tutup harian saham Alibaba, hingga didapatkan hasil forecasting untuk 60 hari selanjutnya setelah Desember 2024 berdasarkan model XGBoost dan LSTM pada Gambar **2.1**.

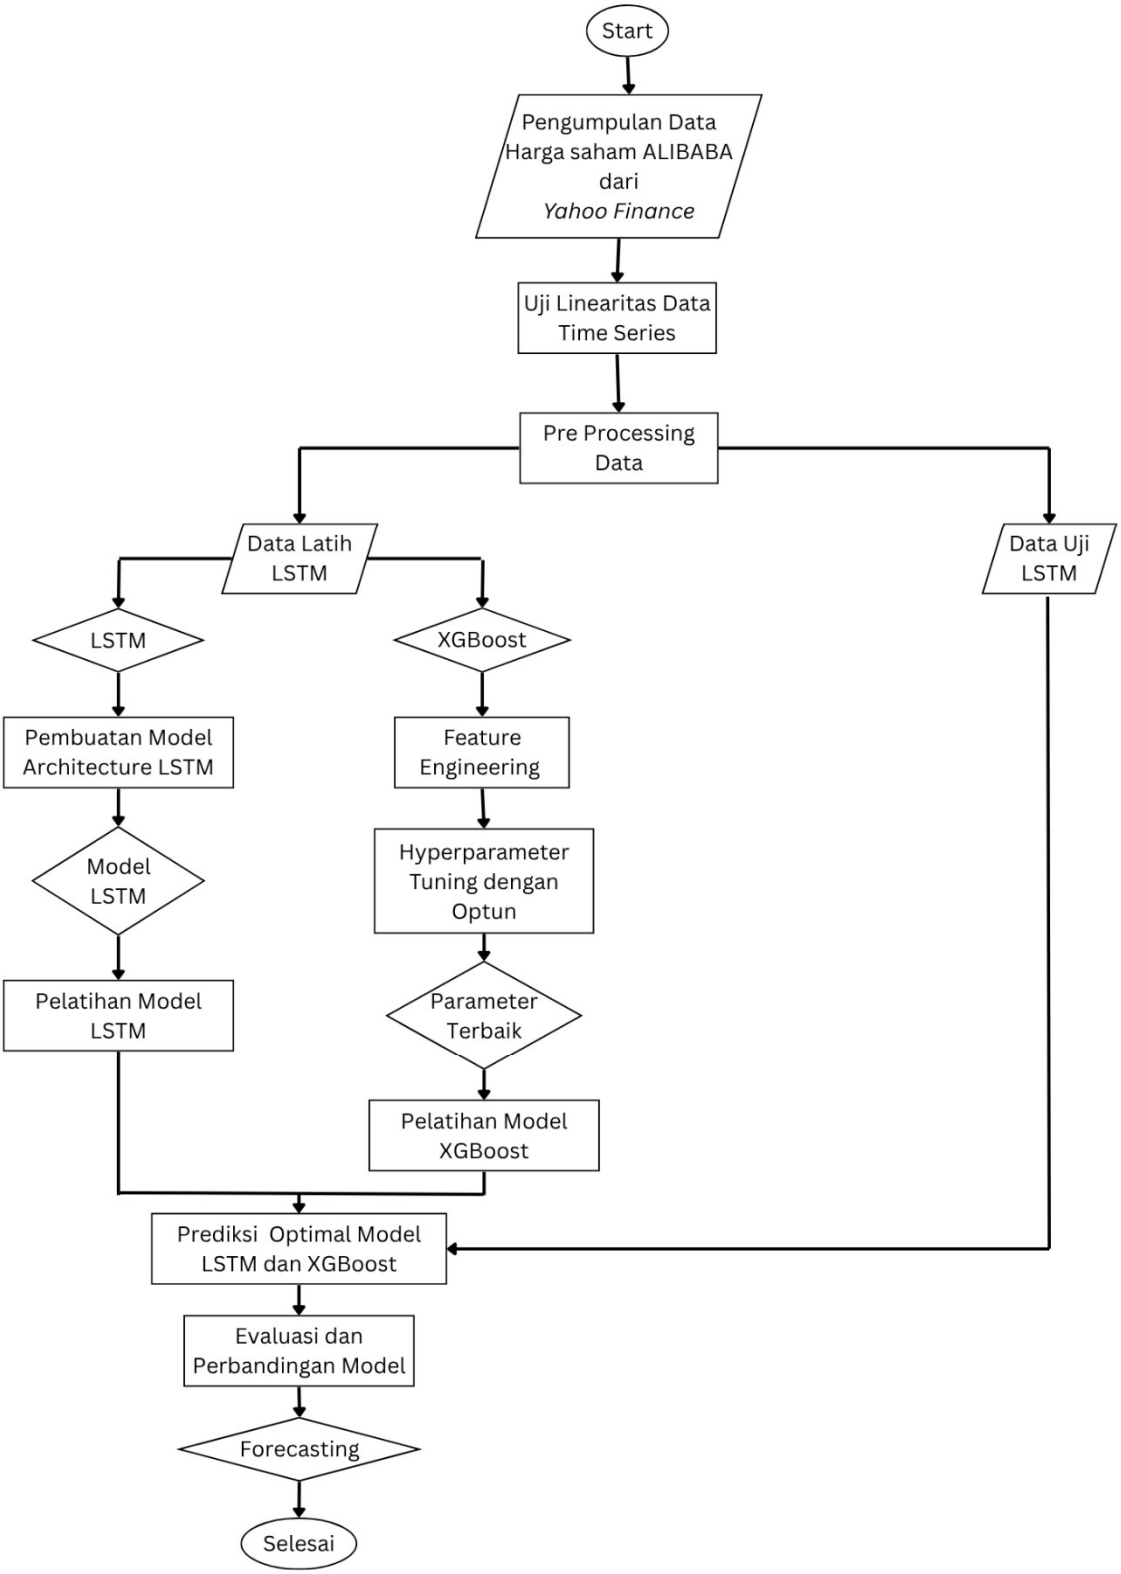

Gambar 3.1. Diagram Alir Penelitian

4. HASIL DAN PEMBAHASAN

4.1 Analisis Karakteristik

Analisis karakteristik dilakukan untuk memahami pola dan sifat dasar dari data yang digunakan dalam penelitian. Bagian ini mencakup statistik deskriptif dan visualisasi deret waktu guna mendukung proses modeling selanjutnya.

4.1.1 Statistika Deskriptif Data Alibaba

Statistika deskriptif digunakan untuk memberikan gambaran umum mengenai karakteristik data harga penutupan (*Close*) saham Alibaba yang digunakan dalam penelitian ini. Ringkasan statistik ini membantu dalam memahami sebaran data, identifikasi nilai ekstrim, serta menentukan langkah pra-pemrosesan yang diperlukan sebelum dilakukan pemodelan lebih lanjut.

Tabel 4.1. Statistika Deskriptif Penutupan (*Close*) Harga Saham Alibaba

Jumlah	Rata-Rata	Standar Deviasi	Minimum	25%	50%	75%	Maksimum
2516	82.322.925	44.329.813	24.414.944	46.201.248	64.300.541	120.278.557	197.696.884

Berdasarkan Tabel 4.1, jumlah data yang dianalisis sebanyak 2.516 observasi harian, yang mencerminkan cakupan data yang cukup luas selama periode pengamatan. Nilai rata-rata harga penutupan tercatat sebesar 82.322,93, yang dapat dianggap sebagai representasi pusat data secara umum. Simpangan baku sebesar 44.329,81 menunjukkan adanya sebaran nilai yang relatif tinggi dari rata-rata, yang mengindikasikan bahwa harga penutupan mengalami fluktuasi cukup besar selama periode tersebut. Tingginya standar deviasi ini mengarah pada tingkat volatilitas yang perlu diperhatikan dalam konteks peramalan saham.

Nilai minimum harga penutupan tercatat sebesar 24.414,94, sedangkan nilai maksimum mencapai 197.696,88. Rentang nilai yang sangat lebar antara minimum dan maksimum (lebih dari 170.000) memperkuat indikasi bahwa data mengandung pergerakan harga yang ekstrem, baik penurunan tajam maupun lonjakan harga tinggi. Nilai kuartil pertama (25%) sebesar 46.201,25 menunjukkan bahwa seperempat dari total data memiliki nilai di bawah harga tersebut. Sementara itu, nilai median atau kuartil kedua (50%) sebesar 64.300,54 menandakan bahwa separuh dari data harga penutupan berada di bawah angka ini. Kuartil ketiga (75%) mencapai 120.278,56, yang berarti hanya 25% dari total data yang berada di atas angka tersebut. Perbedaan besar antara kuartil kedua dan ketiga juga mencerminkan adanya kelompok data yang mengalami kenaikan harga yang signifikan pada periode tertentu. Hal ini penting diperhatikan karena bisa menjadi penanda fase-fase pasar *bullish* atau adanya sentimen pasar yang kuat terhadap saham Alibaba pada waktu-waktu tertentu.

4.1.2 Visualisasi *Time Series* Data Alibaba

Visualisasi data time series digunakan untuk memahami pola dan pergerakan harga penutupan (Close) saham Alibaba selama periode 2015 hingga 2024.

Gambar 4.1. Plot *Time Series* Data Alibaba

Berdasarkan Gambar 4.1, grafik menunjukkan bahwa pada awal periode, harga saham bergerak relatif stabil dalam kisaran USD 60–100. Memasuki tahun 2017, terjadi tren kenaikan yang cukup tajam hingga mencapai puncak di atas USD 300 pada tahun 2020. Setelah mencapai titik tertinggi, harga saham mengalami penurunan signifikan dari akhir 2020 hingga 2022. Penurunan ini berlangsung cukup tajam dan konsisten, mengembalikan harga ke kisaran di bawah USD 100. Hal ini kemungkinan disebabkan oleh berbagai faktor eksternal seperti kondisi pasar global dan tekanan regulasi di Tiongkok terhadap sektor teknologi.

Pada periode 2023 hingga awal 2025, harga saham cenderung bergerak *sideways* dengan fluktuasi yang moderat. Tidak terlihat adanya tren kenaikan atau penurunan yang dominan, namun volatilitas tetap terjadi dalam jangka pendek. Pola pergerakan ini menunjukkan bahwa model prediktif yang digunakan perlu mampu menangkap dinamika nonlinier dan variatif dalam data.

4.2 Uji Linearitas Data *Time Series*

Untuk menguji ada atau tidaknya pola non-linear dalam data, salah satu metode statistik yang digunakan dalam penelitian ini adalah Uji *Neural Network* Terasvirta. Uji Terasvirta dirancang untuk mendeteksi non-linearitas pada data deret waktu (*time series*) dengan menggunakan pendekatan jaringan saraf. Mekanismenya bekerja dengan membandingkan model linear standar melawan model jaringan saraf *feed-forward* sederhana. Tujuannya adalah untuk melihat apakah penambahan komponen non-linear tersebut secara signifikan mampu menjelaskan pola data dengan lebih baik. Dalam konteks peramalan harga saham Alibaba, uji ini menjadi alat diagnostik penting. Hasilnya membantu menentukan apakah pendekatan model yang lebih kompleks dan fleksibel seperti XGBoost dan LSTM untuk menangkap dinamika harga secara akurat. Pengujian linearitas dengan metode ini akan dijelaskan lebih lanjut sebagai berikut.

Hipotesis:
H_0 : Model linear sudah memadai dalam menjelaskan pola data (tidak terdapat hubungan nonlinear)
H_1 : Model linear tidak memadai (terdapat hubungan non-linear dalam data)

Taraf Signifikansi:
α = 5% = 0,05

Daerah Kritis:
X^2 = 6,311; df = 2; p - $value$ = 0.04262

Keputusan dan Kesimpulan:

Berdasarkan hasil uji statistik, diperoleh nilai *p-value* 0,04262. Karena nilai ini berada di bawah taraf signifikansi 0,05, maka keputusan yang diambil adalah Tolak hipotesis nol (H_0). Penolakan H_0 ini memberikan bukti bahwa model linear tidak memadai untuk menjelaskan pola data, yang berarti terdapat adanya struktur non-linear. Temuan ini menjadi landasan metodologis yang mendukung penggunaan model non-linear seperti XGBoost dan LSTM pada penelitian ini.

4.3 *Pre-Processing* Data

Dalam tahap *pre-processing*, data historis disiapkan secara cermat untuk pemodelan dengan LSTM dan XGBoost guna memastikan kualitas dan kesiapan data. Langkah pertama adalah pembagian data secara kronologis, di mana keseluruhan dataset dipisahkan menjadi dua bagian utama yaitu data latih (*training set*) dan data uji (*testing set*). Data latih berfungsi sebagai bahan belajar bagi kedua model untuk mengenali pola-pola historis, sementara data uji, yang merupakan data baru yang belum pernah dilihat model, digunakan untuk mengukur seberapa akurat performa prediksi model nantinya. Selanjutnya, diterapkan sebuah langkah untuk model LSTM, yaitu normalisasi data. Proses ini, yang bertujuan untuk mengubah skala nilai ke rentang seragam seperti 0 hingga 1 untuk menjaga stabilitas dan mempercepat proses komputasi pada model berbasis *neural network*, sedangkan model berbasis pohon seperti XGBoost tidak sensitif terhadap skala data. Untuk mencegah kebocoran data (*data leakage*) dan menjaga objektivitas evaluasi, parameter normalisasi seperti nilai minimum dan maksimum dihitung dari data latih, yang kemudian digunakan untuk mentransformasi baik data latih maupun data uji yang akan digunakan oleh LSTM.

4.3.1 Normalisasi Data

Sebelum data harga penutupan saham Alibaba dimasukkan ke dalam model LSTM, dilakukan proses normalisasi untuk menyamakan skala dan menjaga kestabilan proses pelatihan. Normalisasi dilakukan terhadap variabel harga penutupan (Close) menggunakan metode Min-Max Scaling dari pustaka Scikit-Learn, yang mentransformasi seluruh nilai ke dalam rentang [0, 1]. Untuk menjaga objektivitas evaluasi dan mencegah kebocoran informasi (data leakage), objek MinMaxScaler hanya di-fit pada data pelatihan. Nilai minimum dan maksimum yang diperoleh dari data pelatihan masing-masing sebesar USD 55.42 dan USD 306.27 digunakan untuk mentransformasi baik data pelatihan maupun data pengujian.

Setelah transformasi, data harga yang semula berada dalam skala besar berhasil dikonversi ke rentang kecil yang seragam. Hasil transformasi ini kemudian divisualisasikan pada Gambar 4.2 untuk menggambarkan dampak normalisasi terhadap skala data.

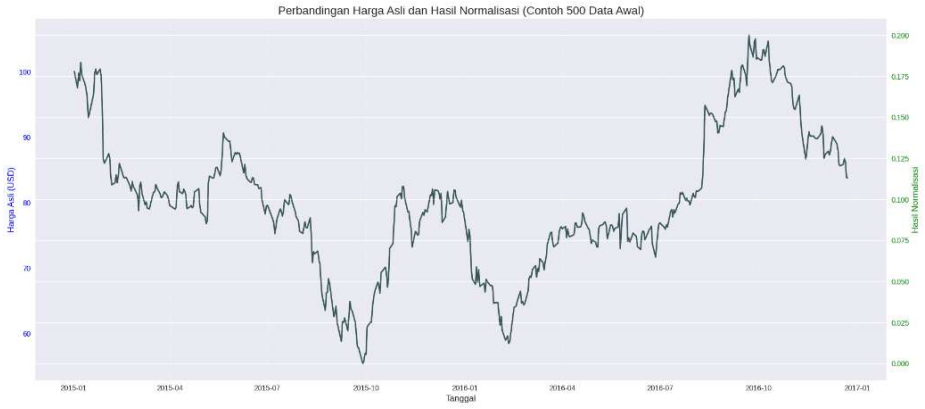

Gambar 4.2 Perbandingan Harga Penutupan Sebelum dan Sesudah Normalisasi pada 500 Data Awal

4.3.2 Pembagian Data In Sample dan Out Sample (Training dan Testing)

Langkah pertama dalam analisis data deret waktu untuk penelitian ini adalah membagi dataset menjadi dua bagian yaitu data latih (*training*) dan data uji (*testing*). Pembagian ini penting untuk mengevaluasi kemampuan generalisasi model, yaitu dengan melatih model menggunakan data historis (latih) dan kemudian menguji kemampuannya untuk meramal data yang belum pernah dilihat sebelumnya (uji). Penelitian ini menggunakan total 2516 data observasi harian harga saham Alibaba dari Januari 2015 hingga Desember 2024, yang bersumber dari Yahoo Finance. Data tersebut kemudian dibagi menjadi data latih dan data uji, di mana rincian data latih disajikan pada **Tabel 4.2** .

Tabel 4.2. Data Pelatihan

Data Pelatihan (*Training Set*)	
Date	**BABA**
2015-01-02	100,051353
2015-01-05	97,540405
⋮	⋮
2022-12-30	85,072616

Kemudian untuk data tes ditunjukkkan pada **Tabel 4.3**.

Tabel 4.3. Data Pengujian

Data Pengujian (*Testing Set*)	
Date	**BABA**
2023-01-03	88,829376
2023-01-04	100.360382
⋮	⋮
2024-12-30	84.129997

Berdasarkan Tabel 4.2 dan Tabel 4.3 data harga saham BABA telah dibagi menjadi dua kelompok utama yaitu data pelatihan (*training set*) dan data pengujian (*testing set*). Data pelatihan, yang ditampilkan pada Tabel 4.2, mencakup harga penutupan harian dari tanggal 2 Januari 2015 hingga 30 Desember 2022. Kumpulan data historis ini digunakan untuk membangun dan melatih model, sehingga algoritma dapat mempelajari pola dan tren dari masa lalu. Sementara itu, Tabel 4.3 merinci data pengujian, yang terdiri dari harga penutupan dari 3 Januari 2023 hingga 30 Desember 2024. Data ini digunakan untuk mengevaluasi kinerja model terhadap data yang belum pernah dilihat sebelumnya, untuk mengukur seberapa baik kemampuannya dalam melakukan peramalan.

4.4 Model LSTM

Model LSTM (Long Short-Term Memory) yang digunakan dalam penelitian ini dirancang untuk memprediksi harga saham harian Alibaba berdasarkan 60 hari data sebelumnya (disebut sebagai *sequence length*). Arsitektur model dibangun menggunakan library Keras dengan pendekatan sekuensial (*Sequential API*) yang memungkinkan susunan layer secara bertahap dari input hingga output.

4.4.1 Arsitektur Model LSTM

Model Architecture:
Model: "sequential"

Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 60, 50)	10,400
dropout (Dropout)	(None, 60, 50)	0
lstm_1 (LSTM)	(None, 60, 50)	20,200
dropout_1 (Dropout)	(None, 60, 50)	0
lstm_2 (LSTM)	(None, 50)	20,200
dropout_2 (Dropout)	(None, 50)	0
dense (Dense)	(None, 25)	1,275
dense_1 (Dense)	(None, 1)	26

Total params: 52,101 (203.52 KB)
Trainable params: 52,101 (203.52 KB)
Non-trainable params: 0 (0.00 B)

Gambar 4.3 Model Architecture LSTM

1. Layer LSTM pertama memiliki 50 unit (neuron) dan menerima input dengan urutan 60 langkah (60 hari terakhir). return_sequences=True digunakan agar seluruh urutan keluaran diteruskan ke layer berikutnya. Parameter dihitung dari: (input_dim + output_dim + 1) * output_dim = (1 + 50 + 1) * 50 = 10,400.
2. Dropout bertugas mematikan (drop) 20% neuron secara acak saat training, sehingga mencegah overfitting. Tidak memiliki parameter yang dilatih.
3. Layer LSTM kedua juga memiliki 50 unit dan menerima urutan dari layer sebelumnya. return_sequences=True digunakan untuk menjaga bentuk output tetap sebagai urutan.
4. Dropout kedua juga mencegah overfitting dengan cara yang sama.
5. Layer LSTM ketiga mengembalikan output terakhir saja (return_sequences=False). Ini bertujuan untuk menyederhanakan output menjadi satu vektor berdimensi 50, yang akan digunakan sebagai input ke layer Dense.
6. Dropout terakhir di antara LSTM dan Dense layer.
7. Layer Dense pertama memiliki 25 neuron dan berfungsi sebagai layer transformasi awal sebelum hasil akhir. Parameter dihitung dari: (input_dim + 1) * output_dim = (50 + 1) * 25 = 1,275.
8. Layer Dense terakhir terdiri dari 1 neuron karena model hanya memprediksi satu nilai yaitu harga saham keesokan harinya. Parameter: (25 + 1) * 1 = 26.

4.4.2 Proses Pelatihan Model LSTM

Setelah arsitektur model LSTM dibangun, tahap selanjutnya adalah melakukan pelatihan terhadap data pelatihan yang telah dibentuk dalam format sekuensial menggunakan panjang jendela waktu sebesar 60 hari. Setiap sampel input terdiri atas 60 harga penutupan sebelumnya, sedangkan nilai targetnya adalah harga pada

hari ke-61. Dengan demikian, model dapat mempelajari keterkaitan historis dari pergerakan harga dalam suatu horizon waktu yang terbatas.

Model dikompilasi menggunakan fungsi kerugian Mean Squared Error (MSE) dan dioptimasi menggunakan algoritma Adam Optimizer. Proses pelatihan dijalankan selama 100 epoch dengan ukuran batch sebesar 64, serta menggunakan validation split sebesar 20% dari data pelatihan sebagai data validasi internal. Selama proses pelatihan, dilakukan pemantauan terhadap performa model menggunakan dua metrik, yaitu *loss* dan *Mean Absolute Error (MAE)*, baik untuk data pelatihan maupun validasi.

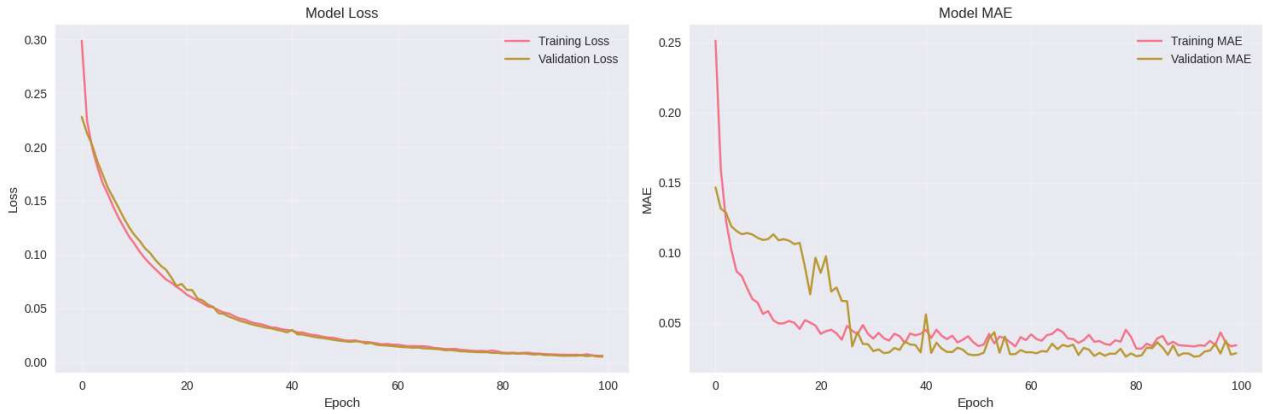

Gambar 4.4 Grafik Loss dan MAE Model LSTM selama 100 Epoch.

Pada awal pelatihan, nilai *training loss* tercatat sekitar 0.30 dan secara konsisten menurun hingga mencapai nilai mendekati 0.01 pada akhir epoch ke-100. Sementara itu, *validation loss* juga menurun dari sekitar 0.23 menjadi kurang dari 0.02, menunjukkan bahwa model mampu mempelajari data tanpa terjadi overfitting yang signifikan. Nilai *training MAE* juga mengalami penurunan dari sekitar 0.25 menjadi 0.01, sedangkan *validation MAE* menurun dari 0.14 menjadi sekitar 0.02. Pola penurunan ini mengindikasikan bahwa model mampu menghasilkan prediksi dengan tingkat kesalahan yang rendah baik pada data pelatihan maupun validasi.

Untuk menjaga kualitas pelatihan, digunakan strategi early stopping dengan *patience* sebanyak 10 epoch untuk menghentikan pelatihan ketika model tidak lagi mengalami peningkatan pada data validasi. Selain itu, digunakan juga model checkpoint untuk menyimpan bobot model terbaik berdasarkan nilai *val_loss* terendah selama pelatihan berlangsung.

Setelah proses pelatihan selesai dan model terbaik diperoleh, dilakukan prediksi terhadap data pengujian yang mencakup periode dari Januari 2023 hingga Desember 2024. Model menerima masukan berupa 60 hari harga penutupan terakhir dan menghasilkan prediksi harga untuk hari ke-61 secara berulang dalam skema rolling window.

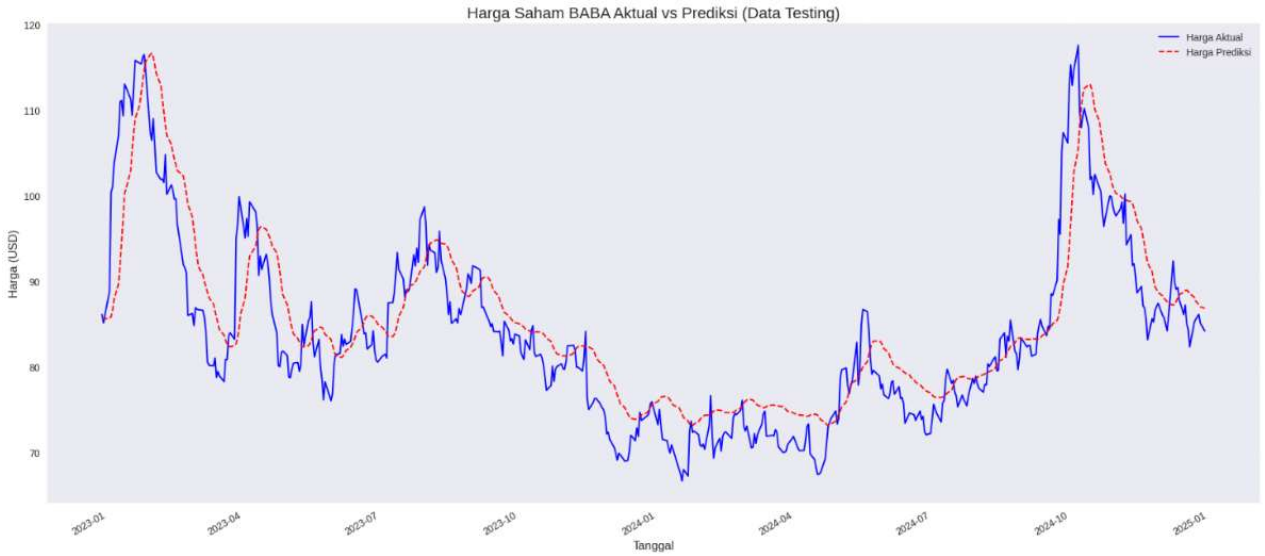

Gambar 4.5 Grafik Perbandingan Harga Saham Aktual dan Prediksi Model LSTM pada Data Uji.

Pada Gambar 4.5 memperlihatkan perbandingan antara harga aktual dan hasil prediksi model pada periode pengujian. Dari grafik terlihat bahwa model mampu mengikuti arah pergerakan harga saham secara umum, khususnya pada tren naik dan turun jangka menengah. Namun, terdapat sedikit keterlambatan respons (lagging) pada titik-titik ekstrim seperti lonjakan harga mendadak, yang merupakan karakteristik umum dari model berbasis urutan deterministik seperti LSTM.

4.5 Model XGBoost

Pada bagian ini membahas secara rinci pembangunan model XGBoost untuk prediksi harga saham Alibaba Group (BABA). Fokus utama adalah pada tahapan *feature engineering*, proses *hyperparameter tuning* menggunakan Optuna, dan evaluasi kinerja model XGBoost berdasarkan metrik dan visualisasi.

4.5.1 *Feature Engineering*

Proses *feature engineering* ini bertujuan untuk menangkap pola dan tren yang mungkin tidak terlihat dari data awal. Dalam analisis kali ini, *Feature engineering* melibatkan beberapa kategori utama sebagai berikut:

1. Fitur Berbasis Waktu: Fitur-fitur ini mengekstrak informasi temporal dari indeks tanggal. Ini termasuk tahun, bulan, hari dalam seminggu, hari dalam sebulan, kuartal, dan minggu dalam setahun. Fitur-fitur ini membantu model memahami pola musiman atau mingguan dalam pergerakan harga saham.
2. Fitur '*Lagged'* (Nilai Historis): Fitur ini merepresentasikan harga penutupan (Close) dari periode sebelumnya. Berbagai periode *lag* yang diterapkan, yaitu lag ke 1, 2, 3, 5, 7, 10, 14, dan 21. Fitur *lagged* sangat penting dalam analisis deret waktu karena harga saham saat ini sangat dipengaruhi oleh harga di masa lalu.
3. Fitur *Rolling Window* (*Moving Average* dan Standar Deviasi): Fitur ini dihitung dari *moving average* (MA) dan standar deviasi (STD) harga penutupan selama periode waktu tertentu. Ukuran 'window' yang digunakan adalah 5, 10, 20, 50, 100, dan 200 hari. *Moving average* membantu menghaluskan fluktuasi harga jangka pendek dan mengidentifikasi tren, sementara standar deviasi mengukur volatilitas harga.
4. Fitur Momentum (Berdasarkan *Moving Average*): Fitur momentum menangkap kekuatan atau kecepatan pergerakan harga. Ini dihitung sebagai perbedaan atau rasio antara *moving average* yang berbeda (contoh: MA_5_vs_20, MA_10_vs_50) dan harga relatif terhadap *moving average* tertentu (contoh: price_relative_to_MA5, price_relative_to_MA20, price_relative_to_MA50). Fitur-fitur ini membantu model mengidentifikasi potensi titik balik atau kelanjutan tren.

Berbagai fitur yang digunakan tersebut akan memengaruhi jumlah data nantinya, khususnya pada fitur *rolling window* dan *lagged* yang menggeser data sehingga beberapa data di awal akan dikeluarkan karena memiliki nilai 'NaN' di dalam fiturnya. Namun, informasi data yang dikeluarkan tersebut tidak akan berkurang karena telah dimasukkan pada fitur-fitur tersebut.

4.5.2 *Hyperparameter Tuning* dengan Optuna

Setelah proses *feature engineering*, langkah selanjutnya adalah mengoptimalkan *hyperparameter* model XGBoost menggunakan *library* Optuna. Optuna adalah *framework* untuk optimalisasi *hyperparameter* yang secara otomatis menemukan set *hyperparameter* terbaik dengan mengeksplorasi model secara efisien. Proses *hyperparameter tuning* menggunakan Optuna dalam dilihat sebagai berikut:

1. **Pembagian Data Validasi:** Data pelatihan awal dibagi lagi menjadi *train set* (80%) dan *validation set* (20%). Pembagian ini penting untuk mencegah *data leakage* selama proses *hyperparameter tuning*, memastikan bahwa model diuji pada data yang belum pernah dilihat sebelumnya.
2. **Fungsi Objektif:** Fungsi objektif didefinisikan untuk Optuna, yang bertujuan untuk meminimalkan *Root Mean Squared Error* (RMSE) pada data validasi. RMSE dipilih sebagai metrik evaluasi karena memberikan bobot lebih besar pada kesalahan yang lebih besar, yang penting dalam prediksi harga saham.
3. **Pemilihan *Hyperparameter*:** Optuna secara otomatis menjelajahi berbagai kombinasi dari *hyperparameter* yang diberikan. Untuk berbagai *hyperparameter* yang digunakan dalam analisis dapat dilihat pada tabel berikut.

Table 4.4 *Hyperparameter Tuning* yang digunakan dalam Optuna

Hyperparameter	**Nilai**
n_estimators	100 - 2000
learning_rate	0.01 – 0.3
max_depth	3 – 10
subsample	0.6 – 1
colsample_bytree	0.6 – 1
gamma	0.0 – 0.5
reg_alpha	0.0 – 0.5
reg_lambda	0.0 – 0.5
random_state	42
n_jobs	-1

Melalui eksplorasi iteratif ini, Optuna berhasil mengidentifikasi kombinasi *hyperparameter* optimal yang menghasilkan kinerja prediksi terbaik pada data validasi. Model XGBoost kemudian diinisialisasi dan dilatih menggunakan *hyperparameter* terbaik yang telah didapatkan ini.

4.5.3 Hasil Analisis Model

Pada bagian ini, *hyperparameter* terbaik yang telah didapatkan sebelumnya akan digunakan untuk membuat model di dalam data testing, yang kemudian akan diukur menggunakan beberapa metrik evaluasi sebagai ukuran perbandingan kebaikan model. Untuk hasil yang didapatkan dari model tersebut dapat dilihat pada plot antara harga saham aktual dan harga yang telah diprediksi oleh model seperti pada gambar berikut.

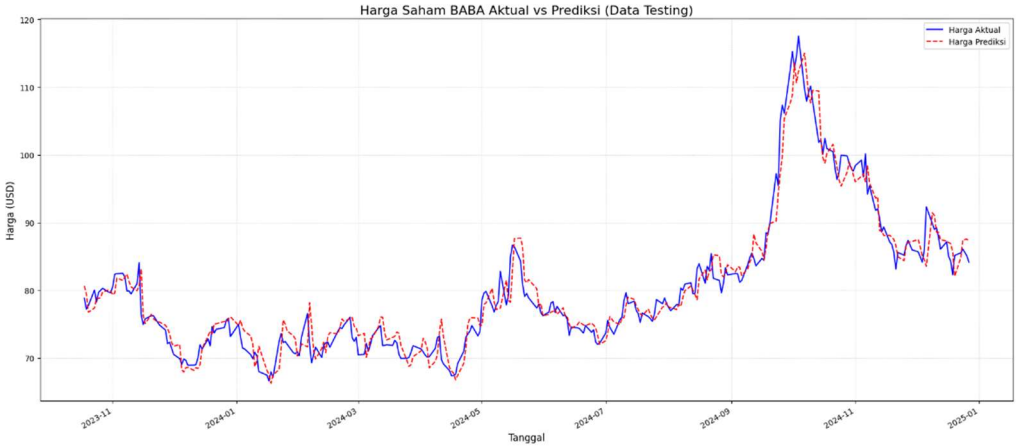

Gambar 4.6 Plot Harga Saham Aktual vs Harga Prediksi

Dalam grafik tersebut, garis biru mewakili harga saham BABA yang sesungguhnya, sedangkan garis putus-putus berwarna merah menunjukkan harga yang telah diprediksi oleh model XGBoost. Dapat dilihat bahwa garis prediksi secara konsisten mengikuti pergerakan tren harga aktual dengan tingkat akurasi yang sangat tinggi. Model berhasil menangkap baik arah naik maupun turunnya harga saham, menunjukkan kemampuannya dalam memahami dinamika pasar. Meskipun terdapat sedikit deviasi pada beberapa titik puncak atau lembah yang ekstrem, secara keseluruhan, prediksi model tetap sangat dekat dengan data aktual. Konsistensi ini terlihat sepanjang periode pengujian yang disajikan (*data testing*). Kemampuan model untuk secara akurat memprediksi pergerakan harga saham, bahkan di tengah volatilitas, menegaskan bahwa kombinasi *feature engineering* yang kaya dan *hyperparameter tuning* yang efektif telah menghasilkan model XGBoost yang sangat andal untuk tugas prediksi ini.

4.6 Evaluasi dan Perbandingan Model

Setelah pemodelan data saham Alibaba dilakukan menggunakan metode LSTM dan XGBoost, performa kedua model dievaluasi. Evaluasi ini menggunakan data latih dan data uji untuk mengukur tingkat kesalahan prediksi. Metrik yang digunakan untuk evaluasi adalah *Mean Absolute Error* (MAE*), Root Mean*

Squared Error (RMSE), dan Koefisien Determinasi (R-Squared). Perbandingan hasil evaluasi dari kedua model tersebut disajikan dalam Tabel 4.5.

Table 4.5. Nilai Evaluasi Tiap Model Pendekatan

Model	Data *Train*			Data *Test*		
	MAE	RMSE	R-Squared	MAE	RMSE	R-Squared
LSTM	6,0320	8,1943	0,9800	3,9384	5,2223	0,7702
XGBoost	2,4707	3,3628	0,9965	1,7103	2,3462	0,9475

Berdasarkan hasil evaluasi yang disajikan pada tabel, model XGBoost menunjukkan performa yang paling unggul dalam memprediksi harga saham Alibaba. Pada data pengujian (testing set), model XGBoost mencatatkan nilai eror yang jauh lebih rendah, dengan MAE sebesar 1,7103 dan RMSE sebesar 2,3462. Sebaliknya, model LSTM menghasilkan nilai eror yang lebih tinggi dengan MAE 3,9384 dan RMSE 5,2223. Dari sisi R-Squared, XGBoost juga lebih superior dengan nilai 0,9475 dibandingkan LSTM yang hanya mencapai 0,7702 pada data pengujian. Meskipun kedua model menunjukkan akurasi yang tinggi pada data pelatihan, XGBoost membuktikan kemampuan generalisasi yang lebih baik. Hal ini terlihat dari performanya yang tetap stabil dan tidak menurun secara drastis saat diuji pada data baru. Oleh karena itu, XGBoost dipilih sebagai model terbaik dalam penelitian ini karena kemampuannya memberikan prediksi yang paling akurat dan andal.

Tahap selanjutnya adalah melakukan peramalan harga saham Alibaba untuk 60 hari ke depan. Proses ini menggunakan model terbaik yaitu XGBoost, yang sebelumnya telah terbukti memberikan performa terbaik berdasarkan hasil evaluasi. Model XGBoost digunakan untuk memproyeksikan pergerakan harga saham, dimulai dari titik data historis terakhir hingga 60 periode harian berikutnya. Visualisasi lengkap dari hasil peramalan tersebut ditampilkan pada Gambar 4.7.

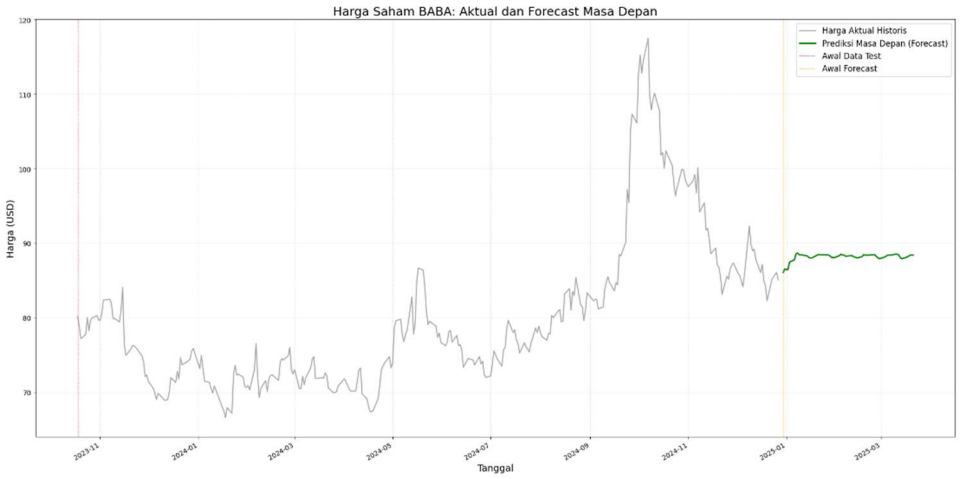

Gambar 4.7 Forecast Harga Saham BABA 60 Hari ke Depan Menggunakan Model Terbaik

Gambar 4.7 menampilkan hasil visualisasi peramalan dari model XGBoost, yang tersambung dengan data historis setelah periode pengujian berakhir. Pada grafik, Terlihat bahwa model memproyeksikan pergerakan harga yang cenderung stabil dengan sedikit kenaikan minor di awal periode peramalan. Pola ini mencerminkan kecenderungan model XGBoost untuk membuat prediksi konservatif di masa depan. Model tampaknya mengidentifikasi momentum pemulihan harga terkini namun tidak memproyeksikan volatilitas tinggi seperti yang terlihat pada data historisnya. Meskipun hasil prediksi ini tampak jauh lebih halus dibandingkan pergerakan aktual di masa lalu, tren yang stabil ini memberikan sebuah estimasi yang masuk akal dan berbasis pada kondisi pasar terbaru sebelum periode peramalan dimulai.

5. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa karakteristik pergerakan harga saham Alibaba (BABA) periode 2015 hingga 2024 menunjukkan pola volatilitas yang tinggi dengan tren fluktuatif yang signifikan. Uji linearitas menggunakan metode Neural Network Terasvirta menunjukkan

bahwa data harga saham Alibaba bersifat non-linear, sehingga pendekatan model non-linear dinilai lebih tepat untuk peramalan harga saham tersebut. Dalam penelitian ini, dua metode peramalan deret waktu, *yaitu Long Short-Term Memory* (LSTM) dan *Extreme Gradient Boosting* (XGBoost) telah dibandingkan dari segi performa prediksi harga saham harian. Hasil evaluasi menunjukkan bahwa XGBoost mampu menghasilkan prediksi harga saham yang lebih akurat dibandingkan LSTM, dengan nilai MAE dan RMSE yang lebih kecil, serta nilai R-Squared yang lebih tinggi baik pada data latih maupun uji. Hal ini membuktikan bahwa XGBoost memiliki kemampuan generalisasi yang lebih baik terhadap data baru, serta lebih adaptif terhadap pola data yang kompleks dan non-linear. Oleh karena itu, penelitian ini merekomendasikan model XGBoost sebagai metode yang lebih efektif dan andal untuk peramalan harga saham Alibaba, sekaligus dapat dijadikan referensi bagi investor dalam mendukung pengambilan keputusan investasi berbasis data historis pasar saham.

DAFTAR PUSTAKA

[1] S. E. Suryana, B. Warsito dan S. Suparti, "Penerapan Greadient Boosting Dengan Hyperopt Untuk Memprediksi Keberhasilan Telemarketing Bank," Jurnal Gaussian, 2021.

[2] T. Chen, P. Samaranayake, X. Cen, M. Qi dan Y.-C. Lan, "The Impact of Online Reviews on Comsumers Purchasing Decisions: Evidence From an Eye-Tracking Study," Frontiers in Psychology, 2022.

[3] S. Singh, "Mobile Phone Companies Increasing Market Share Trough Innovations, R&D Spending and Patents," Emerging Markets Journal, 2022.

[4] M. Abdurohman dan A. G. Putrada, "Forecasting Model for Lighting Electricity Load with a Limited Dataset using XGBoost," KINETIK: Game Technology, Information System, Computer Network, Computing, Electronics, and Control, 2023.

[5] D. Breskuviene dan G. Dzemyda, "Categorical Feature Encoding Techiques for Improved Classifier Performance when Dealing with Imbalanced Data of Fraudulent Transactions," International Journal Of Computers Communications & Control, 2023.

[6] Q. Wang, "The analysis of Alibaba Group's future stock price trends and overall status based on the Random Forest mode," J. Globe Scientific Reports, vol. 7, no. 2, p. 141, 2025. https://doi.org/10.69610/j.gsr.2025031701

[7] F. Petropoulos et al., "Forecasting: theory and practice," International Journal of Forecasting, vol. 38, no. 3, pp. 705–871, Jul.–Sep. 2022. [Online]. https://doi.org/10.1016/j.ijforecast.2021.11.001

[8] H. Madsen, Time Series Analysis, 1st ed. New York: Chapman and Hall/CRC, 2007. [Online]. https://doi.org/10.1201/9781420059687

[9] Terasvirta, T., & Lin, C. F. J. (2015). Neural Network Linearity Tests and Smooth Transition Autoregressive Models. Studies in Nonlinear Dynamics & Econometrics, 19(3), 285–308. https://doi.org/10.1515/snde-2013-0073

[10] Terasvirta, T. (2016). Nonlinear Time series Modeling: A Selective Review. Statistical Papers, 57(1), 7–34. https://doi.org/10.1007/s00362-014-0635-z

[11] Zhou, M., Gao, Y., & Liu, Q. (2020). Testing Nonlinearity in Economic Time series with Artificial Neural Networks. Computational Economics, 56, 145–163. https://doi.org/10.1007/s10614-019-09903-w

[12] R. Y. Choi, A. S. Coyner, J. Kalpathy-Cramer, M. F. Chiang, and J. P. Campbell, "Introduction to machine learning, neural networks, and deep learning," Translational Vision Science & Technology, vol. 9, no. 2, pp. 14, Feb. 2020. [Online]. https://doi.org/10.1167/tvst.9.2.14

[13] Livieris, I. E., Pintelas, E., Stavroyiannis, S., & Pintelas, P. (2020). Ensemble deep learning models for forecasting cryptocurrency time-series. Algorithms, 13(5), 121. https://doi.org/10.3390/a13050121

[14] Hamayel, M. J., & Owda, A. Y. (2021). A novel cryptocurrency price prediction model using GRU, LSTM and bi-LSTM machine learning algorithms. AI, 2(4), 557–578. https://doi.org/10.3390/ai2040030

[15] Jin, C., & Li, Y. (2023). Cryptocurrency price prediction using frequency decomposition and deep learning. Fractal and Fractional, 7(10), 708. https://doi.org/10.3390/fractalfract7100708

[16] S. Kusumadewi, Artificial Intelligence (Teknik dan Aplikasinya), Yogyakarta: Graha Ilmu, 2003.

[17] L. Fausett, Fundamentals of Neural Networks: Architectures, Algorithms and Applications, Upper Saddle River, NJ: Prentice-Hall, 1994.

[18] M. H. Sultan, "Optimasi Parameter Neural Network Pada Data Time Series Untuk Memprediksi Rata-Rata Kekuatan Gempa," Cauchy: Jurnal Matematika Murni dan Aplikasi, vol. 3, no. 2, pp. 59–63, 2014.

[19] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," Neural Computation, vol. 9, no. 8, pp. 1735-1780, November 1997.

[20] Taylor & Francis Online, "Long Short-Term Memory (LSTM)," Taylor & Francis Online, 26 Februari 2024. [Online]. Tersedia: https://taylorandfrancis.com/knowledge/Engineering_and_technology/Artificial_intelligence/LSTM/ [Diakses: 6 Juli 2025].

[21] V. I. Kontopoulou, A. D. Panagopoulos, I. Kakkos, and G. K. Matsopoulos, "A Review of ARIMA vs. Machine Learning Approaches for Time Series Forecasting in Data Driven Networks," Future Internet, vol. 15, no. 8, p. 255, August 2023.

[22] IBM, "What is XGBoost?", [Online]. Tersedia: https://www.ibm.com/think/topics/xgboost [Diakses: 6 Juli 2025].

[23] A. Chen, "High Accuracy Stock Trend Prediction using XGBoost Model", OSF, 25 Oktober 2023, [Online]. Tersedia: https://doi.org/10.17605/OSF.IO/HMJ53 [Diakses: 6 Juli 2025].

[24] T. Chen & C. Guestrin, "XGBoost: A Scalable Tree Boosting System", Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, hlm. 785–794, 2016.

[25] Y. Zhang, "Stock Price Prediction Method Based on XGboost Algorithm", Atlantis Press, [Online]. Tersedia: https://www.atlantis-press.com/article/125979100.pdf [Diakses: 6 Juli 2025].

[26] S. A. Astiti, "Implementasi Jaringan Syaraf Tiruan Backpropagation untuk Prediksi Permintaan Beras," Jurnal Informatika: Jurnal Pengembangan IT (JPIT), vol. 6, no. 3, pp. 189–193, Sep. 2021.

[27] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd ed., Sebastopol, CA: O'Reilly Media, 2019.
[28] L. Fausett, Fundamentals of Neural Networks: Architectures, Algorithms and Applications, Upper Saddle River, NJ: Prentice-Hall, 1994.
[29] J. Owen, Hyperparameter Optimization with Optuna, 2020. [Online]. Available: https://optuna.org